

Preparação dos dados


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo


francisco@icmc.usp.br

Onde estamos?



Tipos de dados

- Dados não estruturados



Séries temporais

Textos


Die durch lebhaftes Farbenstrahlen ziemlich auffallende Art ist besonders durch die Neigung der hellen Bindenzzeichnung zur Auflösung in eine unregelmäßige Fleckerei, sowie das Auftreten einer kahlen Lateralmarginal- und ventralen angestrichelten Rückenlinie sehr ausgezeichnet. Ähnlich wie bei dem flacheren *D. grandis* Grilla, zieht sich eine nur stärker erhabene Längsrippe, die etwas innerhalb der Schulter beginnt, bis über die Mitte. Im Gegensatz zu dieser Art ist Kopf und Halsschild in viel grösserer Ausdehnung dicht tomentirt, da die schädlere Mittellinie und besonders die viel weniger ausgedehnten Seitenschilde mehr Raum für die Bekleidung übrig lassen. Diese ist sehr dicht, auf dem Halsschild zwischen den kahlen Stellen und auf der Stirn lebhaft ockerfarbig oder rostgelb, der übrige Teil des Kopfes, sowie eine schmale Randung der glanzlosen Mittellinie des Thorax und der Rann ausserhalb der Seitenschilde weislich. Das Grundornament der Flügeldecken ist heller oder dunkler kaffeebraun, die scharf abgehobenen weissen Binden der δ teils unregelmässig begrenzt, teils in eine Reihe von Fleckchen aufgelöst, wodurch der Gesamteindruck von dem der übrigen spanischen *Dacnusa* mit ihren scharf begrenzten, hellen Binden wesentlich abweicht. Von *D. Ubajou* Perez und *Martinez* Perez unterscheidet sich *agustitana*, abgesehen von der Zeichnung, durch die bei diesen beiden Arten ganz fehlenden oder nur angedeuteten Seitenschilde des Halsschildes. Bei *D. alternans* Guerr. ist die kahlte Halsschildmittellinie tief gefurcht und die Marginalbinden der Flügeldecken sehr schmal, ausserdem fehlt bei dieser Art die Rückenrippe. *Sigüenza* *) in Castilien (Korb, 17, 3. 87).

Áudios





Vídeos

Geralmente transformados para o formato atributo-valor (dados estruturados).



Páginas web

Grafos




Imagens

	temperatura (°C)	dor	...	pressão	doente
Paciente 1	38	Sim	...	12.7	Sim
Paciente 2	36	Não	...	12.7	Não
...	...	...	...	...	...
Paciente n	40	Não	...	14	Sim

Dados estruturados

- Representamos os dados por uma matrix **X** de n linhas e d colunas, sendo n o número de observações e d os atributos.
 - Elemento **X_{ij}** representa o atributo j do objeto i .



Representação dos dados

- **Representação de conjunto de dados**
 - Formados por objetos
 - Cada objeto corresponde a uma ocorrência dos dados

	temperatura (°C)	dor	...	pressão	doente
Paciente 1	38	Sim	...	12.7	Sim
Paciente 2	36	Não	...	12.7	Não
...	...	...	...	...	...
Paciente n	40	Não	...	14	Sim

Representação dos dados

- **Representação de conjunto de dados**
 - Formados por objetos
 - Cada objeto corresponde a uma ocorrência dos dados

Objetos	temperatura (°C)	dor	...	pressão	doente
Paciente 1	38	Sim	...	12.7	Sim
Paciente 2	36	Não	...	12.7	Não
...	...	...	...	...	...
Paciente n	40	Não	...	14	Sim

Representação dos dados

- **Representação de conjunto de dados**
 - Formados por objetos
 - Cada objeto corresponde a uma ocorrência dos dados


Objetos	Atributos				
	temperatura (°C)	dor	...	pressão	doente
Paciente 1	38	Sim	...	12.7	Sim
Paciente 2	36	Não	...	12.7	Não
...	...	...	...	...	...
Paciente n	40	Não	...	14	Sim

Representação dos dados

- **Representação de conjunto de dados**
 - Formados por objetos
 - Cada objeto corresponde a uma ocorrência dos dados

Objetos	Atributos				Classe (atributo meta)
	temperatura (°C)	dor	...	pressão	doente
Paciente 1	38	Sim	...	12.7	Sim
Paciente 2	36	Não	...	12.7	Não
...	...	...	...	...	...
Paciente n	40	Não	...	14	Sim

Tipos de dados



Tipos de dados

Quantitativo (numérico)

Representa quantidades.

Valores podem ser ordenados e usados em operações aritméticas.

Podem ser **contínuos** ou **discretos**.

Possuem unidade associada.

Qualitativo (simbólico ou categórico)

Representa qualidades.

Valores podem ser associados a categorias.

Alguns podem ser ordenados, mas operações aritméticas não são aplicáveis.

Ex. {pequeno, médio, grande}

Tipos de dados

Atributos Quantitativos

Contínuos

- Podem assumir um número infinito de valores.
- Geralmente resultados de medidas.
- Frequentemente representados por números reais.
- *Ex. peso, distância*

Discretos

- Número finito ou infinito contável de valores.
- Caso especial: atributos binários (booleanos)
- *Ex. {12, 23, 45}, {0, 1}*

Tipos de dados

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Média	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Alta	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Tipos de dados

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Média	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Alta	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Qualitativo


Quantitativo discreto

Quantitativo contínuo

Tipos de dados

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Média	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Alta	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Qualitativo
Quantitativo discreto
Quantitativo contínuo



Alguns atributos qualitativos são representados por números, mas não faz sentido a utilização de operadores aritméticos sobre seus valores

Escala dos dados

- Define operações que podem ser realizadas sobre os valores dos atributos

- Nominiais
- Ordinais

Qualitativos

- Intervalares
- Racionais

Quantitativos

Escala dos dados

Escala nominal

- Valores são rótulos diferentes e carregam a menor quantidade de informação possível
- Não existe relação de ordem entre os valores.
- **Operações aplicáveis:** $=$, $\neq$
- *Ex.: número de conta em banco, cores, sexo.*

Escala dos dados

Escala nominal

- Valores são rótulos diferentes e carregam a menor quantidade de informação possível
- Não existe relação de ordem entre os valores.
- **Operações aplicáveis:** $=$, $\neq$
- *Ex.: número de conta em banco, cores, sexo.*

Escala ordinal

- Valores refletem ordem das categorias representadas.
- **Operações aplicáveis:** $=$, $\neq$, $<$, $>$, $\leq$, $\geq$
- *Ex.: hierarquia militar, avaliações qualitativas de temperatura*

Escala dos dados

Escala intervalar

- Números que variam em um intervalo.
- É possível definir ordem e diferença em magnitude entre dois valores.
- Origem da escala definida de maneira arbitrária.
- **Operações aplicáveis:** $=$, $\neq$, $<$, $>$, $\leq$, $\geq$, $+$, $-$
- *Ex.: temperatura em $^{\circ}\text{C}$ ou $^{\circ}\text{F}$, datas.*
 - Não podemos afirmar que o ano 2000 é 2 vezes o ano 1000 ou que 4 graus Celsius é 2 vezes mais quente que 2 graus Celsius. Notem $2^{\circ}\text{C} = 275\text{K}$ e $4^{\circ}\text{C} = 277\text{K}$.

Escala dos dados

Escala intervalar

- Números que variam em um intervalo.
- É possível definir ordem e diferença em magnitude entre dois valores.
- Origem da escala definida de maneira arbitrária.
- **Operações aplicáveis:** $=, \neq, <, >, \leq, \geq, +, -$
- *Ex.: temperatura em $^{\circ}\text{C}$ ou $^{\circ}\text{F}$, datas.*
 - Não podemos afirmar que o ano 2000 é 2 vezes o ano 1000 ou que 4 graus Celsius é 2 vezes mais quente que 2 graus Celsius. Notem $2^{\circ}\text{C} = 275\text{K}$ e $4^{\circ}\text{C} = 277\text{K}$.

Escala racional

- Têm significado absoluto (existe 0 absoluto).
- Razão tem significado
- **Operações aplicáveis:** $=, \neq, <, >, \leq, \geq, +, -, *, /$
- *Ex.: salário, saldo em conta, Temperatura em Kelvin.*

Escala dos dados

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Baixa	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Média	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Nominal
Ordinal
Intervalar
Racional

Problemas nos dados







Figure 2.5. Noise in a time series context.




Amostragem



8000 pontos



2000 pontos




500 pontos

Dados incompletos

Case	Attributes			Decision
	Temperature	Headache	Cough	Flu
1	normal	no	no	no
2	*	yes	no	no
3	normal	—	yes	no
4	high	*	?	no
5	high	yes	*	yes
6	very-high	*	no	yes
7	*	no	yes	yes
8	very-high	no	yes	yes

Dados correlacionados



Dados duplicados

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Baixa	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
40	João	RS	21	M	85,9	Alta	Não	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Combinação dados de diferentes tipos

Drug Classification

▲

436

<> Code

Data Card

Code (525)

Discussion (5)

Suggestions (0)

drug200.csv (6.03 kB)

↓

⌵

>

Detail

Compact

Column

6 of 6 columns ▾

About this file


Suggest Edits

The data set contains various information that effect the predictions like Age, Sex, BP, Cholesterol levels, Na to Potassium Ratio and finally the drug type.

# Age Age of the Patient	▲ Sex Gender of the patients	▲ BP Blood Pressure Levels	▲ Cholesterol Cholesterol Levels	# Na_to_K Sodium to potassium Ration in Blood	▲ Drug Drug Type
 1574	M 52% F 48%	HIGH 39% LOW 32% Other (59) 30%	HIGH 52% NORMAL 49%	 6.2738.2	DrugY drugX Other (55)
23	F	HIGH	HIGH	25.355	DrugY
47	M	LOW	HIGH	13.093	drugC
47	M	LOW	HIGH	10.114	drugC
28	F	NORMAL	HIGH	7.798	drugX
61	F	LOW	HIGH	18.043	DrugY
22	F	NORMAL	HIGH	8.607	drugX
49	F	NORMAL	HIGH	16.275	DrugY

<https://www.kaggle.com/datasets/prathamtripathi/drug-classification>

Dados com diferentes escalas




Dados irrelevantes para a análise

Track	Artist	Release Date	Track Score	Spotify Playlist Count	YouTube Views	YouTube Likes
MILLION DOLLAR BABY	Tommy Richman	4/26/2024	725.4	30,716	84,274,754	1,713,126
Not Like Us	Kendrick Lamar	5/4/2024	545.9	28,113	116,347,040	3,486,739
i like the way you kiss me	Artemas	3/19/2024	538.4	54,331	122,599,116	2,228,730
Flowers	Miley Cyrus	1/12/2023	444.9	269,802	1,096,100,899	10,629,796
Houdini	Eminem	5/31/2024	423.3	7,223	77,373,957	3,670,188
Lovin On Me	Jack Harlow	11/10/2023	410.1	105,892	131,148,091	1,392,593
Beautiful Things	Benson Boone	1/18/2024	407.2	73,118	308,723,145	4,120,760
Gata Only	FloyyMenor	2/2/2024	375.8	40,094	228,382,568	1,439,495
BAND4BAND (feat. Lil Baby)	Central Cee	5/23/2024	330.6	10,400	32,735,244	988,682
LUNCH	Billie Eilish	5/17/2024	316.3	13,800	40,022,524	1,307,290
Like That	Future	3/22/2024	308.2	43,025	98,081,493	1,456,177
bathroom floor	Kids With Buns	10/7/2022	301.6	277	6,736,502,312	16,785,489


Número elevado de atributos

Maldição da dimensionalidade



*“O número de exemplos necessários para se aprender um certo conceito cresce exponencialmente de acordo com o número de atributos”
(Valiant, “A Theory of The Learnable”, 1984)*



Atributos que não contribuem para o aprendizado



Dados desbalanceados



Pré-processamento

- Desempenho de técnicas de aprendizado de máquina é afetado pela qualidade dos dados.
 - Conjuntos de dados podem ter diferentes características, dimensões ou formatos.
 - Atributos numéricos vs simbólicos
 - Limpos vs com ruídos e imperfeições
 - Valores incorretos, inconsistentes, duplicados ou ausentes
 - Atributos independentes vs relacionados
 - Poucos vs muitos objetos e/ou atributos

Pré-processamento: minimizar/eliminar problemas nos dados; tornar dados mais adequados para uso por um determinado algoritmo de AM.

- **Benefícios:**

- Facilitar o posterior uso de técnicas de AM
 - Ou tornar mais adequado para a técnica
 - Ex. algumas trabalham somente com entradas numéricas
- Obtenção de modelos mais fiéis à distribuição dos dados
 - Melhorar qualidade
- Redução de complexidade computacional
 - Tempo e custo
- Tornar mais fáceis e rápidos ajustes de parâmetros
- Facilitar a interpretação dos padrões extraídos

Grupos de tarefas de pré-processamento:

- ♦ Eliminação manual de atributos
- ♦ Integração de dados
- ♦ Amostragem de dados
- ♦ Redução de dimensionalidade
- ♦ Balanceamento de dados
- ♦ Limpeza de dados
- ♦ Transformação de dados

Observação: não existe ordem fixa para aplicação das diferentes técnicas de pré-processamento

Eliminação manual de atributos


Track	Artist	Release Date	Track Score	Spotify Playlist Count	YouTube Views	YouTube Likes
MILLION DOLLAR BABY	Tommy Richman	4/26/2024	725.4	30,716	84,274,754	1,713,126
Not Like Us	Kendrick Lamar	5/4/2024	545.9	28,113	116,347,040	3,486,739
i like the way you kiss me	Artemas	3/19/2024	538.4	54,331	122,599,116	2,228,730
Flowers	Miley Cyrus	1/12/2023	444.9	269,802	1,096,100,899	10,629,796
Houdini	Eminem	5/31/2024	423.3	7,223	77,373,957	3,670,188
Lovin On Me	Jack Harlow	11/10/2023	410.1	105,892	131,148,091	1,392,593
Beautiful Things	Benson Boone	1/18/2024	407.2	73,118	308,723,145	4,120,760
Gata Only	FloyyMenor	2/2/2024	375.8	40,094	228,382,568	1,439,495
BAND4BAND (feat. Lil Baby)	Central Cee	5/23/2024	330.6	10,400	32,735,244	988,682
LUNCH	Billie Eilish	5/17/2024	316.3	13,800	40,022,524	1,307,290
Like That	Future	3/22/2024	308.2	43,025	98,081,493	1,456,177
bathroom floor	Kids With Buns	10/7/2022	301.6	277	6,736,502,312	16,785,489






Alguns atributos são irrelevantes para o aprendizado.

Eliminação manual de atributos




- Outro atributo irrelevante facilmente detectado:
 - Atributo que possui o mesmo valor para todos objetos
 - Não traz informação para ajudar a distinguí-los
- Há ainda atributos irrelevantes de identificação não tão clara
 - Técnicas de seleção de atributos podem ajudar a identificar





Dados desbalanceados

- Número de objetos varia para as diferentes classes
 - Típico da aplicação
 - Ex. 80% dos pacientes que vão a um hospital estão doentes.




Classe majoritária
Contém a maior parte dos
exemplos

Classe minoritária
Contém o menor número de
exemplos no conjunto

- Algoritmos tendem a favorecer a classificação na classe majoritária

Dados desbalanceados

- Alternativas para lidar com dados desbalanceados:
 - Obter novos dados para a classe minoritária
 - Na maioria dos casos não é possível..
 - Balancear artificialmente o conjunto de dados:
 - Redefinir o tamanho do conjunto de dados.
 - Usar diferentes custos de classificação para as classes.
 - Induzir um modelo para uma classe.



Limpeza dos dados

- **Qualidade dos dados:**
 - Exemplos de problemas:
 - **Ruídos:** erros ou valores diferentes do esperado
 - **Inconsistências:** não combinam/contradizem valores de outros atributos no mesmo objeto
 - **Redundâncias:** objetos/atributos com mesmos valores
 - **Dados incompletos:** ausência de valores de atributos

Case	Attributes			Decision
	Temperature	Headache	Cough	Flu
1	normal	no	no	no
2	*	yes	no	no
3	normal	—	yes	no
4	high	*	?	no
5	high	yes	*	yes
6	very-high	*	no	yes
7	*	no	yes	yes
8	very-high	no	yes	yes

Limpeza dos dados

- **Exemplos de causas de erros:**
 - Falha humana
 - Falha no processo de coleta de dados
 - Limitações do dispositivo de medição
 - Fraude
 - Valor de atributo muda com o tempo


Case	Attributes			Decision
	Temperature	Headache	Cough	Flu
1	normal	no	no	no
2	*	yes	no	no
3	normal	—	yes	no
4	high	*	?	no
5	high	yes	*	yes
6	very-high	*	no	yes
7	*	no	yes	yes
8	very-high	no	yes	yes

Limpeza dos dados

- **Consequências:**
 - Valores ou objetos inteiros podem ser perdidos
 - Objetos espúrios ou duplicados podem ser obtidos
 - Ex. diferentes registros para mesma pessoa que morou em endereços diferentes
 - Inconsistências
 - Ex.: pessoa com 2m pesando 10 Kg

Limpeza dos dados

- Algumas técnicas de AM conseguem lidar com algumas imperfeições nos dados
 - Outras não conseguem ou apresentam dificuldades
- Porém de forma geral, qualidade das análises pode ser deteriorada



Todas as técnicas se beneficiam de melhora na qualidade dos dados, que pode ser obtida por meio de etapa de **limpeza**

Dados incompletos

Marital status	Course	Nacionality	Admission grade	Gender	Unemployment rate	Inflation rate	GDP	Target
1	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	?	1	142.5	1	13.9	-0.3	0.79	Graduate
1	9130	6	120.0	0	12.4	0.5	1.79	Dropout
1	9773	1	119.6	0	9.4	-0.8	-3.12	Graduate
2	8014	1	141.5	0	?	-0.3	0.79	Graduate
2	?	1	114.8	1	16.2	0.3	?	Graduate
1	9500	1	128.4	0	15.5	2.8	-4.06	Graduate
1	9254	1	113.1	1	?	2.8	-4.06	Dropout
1	9238	62	129.3	0	16.2	0.3	-0.92	Graduate
1	9238	1	123.0	0	8.9	1.4	3.51	Dropout
1	9670	?	130.6	0	?	-0.3	0.79	Graduate
1	9500	1	119.3	0	12.7	3.7	-1.7	Graduate
1	9238	26	132.5	0	13.9	-0.3	0.79	Graduate
1	9085	103	132.2	0	10.8	1.4	1.74	Graduate
1	9556	103	183.5	0	16.2	0.3	-0.92	Dropout
1	9773	1	120.7	0	15.5	2.8	-4.06	Dropout

<https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>



Dados incompletos

- **Possíveis causas:**
 - Atributo não era importante quando primeiros dados foram coletados
 - Ex. e-mail na década de 90
 - Desconhecimento do valor do atributo
 - Ex. não saber tipo sanguíneo de paciente em seu cadastro
 - Falta de necessidade/obrigação de apresentar valor
 - Ex. salário em hospital
 - Inexistência de valor para o atributo
 - Ex. número de partos para pacientes do sexo masculino
 - Problema com equipamento para coleta, transmissão e armazenamento de dados

Dados incompletos

- Algumas técnicas de AM são incapazes de lidar com valores ausentes
 - Geram erro de execução
- Alternativas para lidar com valores ausentes:
 - Eliminar os objetos com valores ausentes
 - Definir e preencher manualmente os valores ausentes
 - Utilizar método/heurística para definir valores automaticamente
 - Empregar algoritmos de AM que lidam internamente com valores ausentes

Dados inconsistentes

- Possuem valores conflitantes em seus atributos

Marital status	Course	Nacionality	Admission grade	Gender	Unemployment rate	Inflation rate	GDP	Target
1	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	9254	1	142.5	1	13.9	-0.3	0.79	Graduate
1	9130	6	120.0	0	12.4	0.5	1.79	Dropout
1	9773	1	119.6	0	9.4	-0.8	-3.12	Graduate
1	171	1	127.3	1	10.8	1.4	1.74	Graduate
2	9991	1	114.8	1	16.2	0.3	-0.92	Graduate
1	9500	1	128.4	0	15.5	2.8	-4.06	Graduate
1	9254	1	113.1	1	15.5	2.8	-4.06	Dropout
1	9238	62	129.3	0	16.2	0.3	-0.92	Graduate
1	9238	1	123.0	0	8.9	1.4	3.51	Dropout
1	9670	1	130.6	0	13.9	-0.3	0.79	Graduate
1	9500	1	119.3	0	12.7	3.7	-1.7	Graduate
1	9238	26	132.5	0	13.9	-0.3	0.79	Graduate
1	9085	103	132.2	0	10.8	1.4	1.74	Graduate
1	9556	103	183.5	0	16.2	0.3	-0.92	Dropout
1	9773	1	120.7	0	15.5	2.8	-4.06	Dropout

Dados inconsistentes

- Algumas inconsistências são de fácil detecção:
 - Violação de relações conhecidas entre atributos
 - Ex.: Valor de atributo A é sempre menor que valor de atributo B
 - Valor inválido para o atributo
 - Ex.: altura com valor negativo
 - Em outros casos, informações adicionais precisam ser verificadas.

Dados redundantes

Marital status	Married	Course	Nacionality	Admission grade	Gender	Unemployment rate	Inflation rate	GDP	Target
1	0	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	0	9254	1	142.5	1	13.9	-0.3	0.79	Graduate
1	0	9130	6	120.0	0	12.4	0.5	1.79	Dropout
1	0	9773	1	119.6	0	9.4	-0.8	-3.12	Graduate
2	1	8014	1	141.5	0	13.9	-0.3	0.79	Graduate
1	0	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	0	9500	1	128.4	0	15.5	2.8	-4.06	Graduate
1	0	9254	1	113.1	1	15.5	2.8	-4.06	Dropout
1	0	9238	62	129.3	0	16.2	0.3	-0.92	Graduate
1	0	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	0	9670	1	130.6	0	13.9	-0.3	0.79	Graduate
1	0	9500	1	119.3	0	12.7	3.7	-1.7	Graduate
1	0	9238	26	132.5	0	13.9	-0.3	0.79	Graduate
1	0	9085	103	132.2	0	10.8	1.4	1.74	Graduate
1	0	9556	103	183.5	0	16.2	0.3	-0.92	Dropout
1	0	9773	1	120.7	0	15.5	2.8	-4.06	Dropout

Dados redundantes

Atributo redundante: valor pode ser estimado a partir de pelo menos um dos demais atributos

- Atributos com a mesma informação preditiva
 - Ex. atributos idade e data de nascimento
 - Ex. atributos quantidade de vendas, valor por venda e venda total
- Atributo redundante pode supervalorizar um dado aspecto dos dados
- Pode também tornar mais lento o processo de indução

Atributos redundantes são geralmente eliminados por técnicas de **seleção de atributos**



Dados redundantes

- Redundância de atributo está relacionada à sua correlação com um ou mais dos demais atributos

Marital status	Married	Course	Nacionality	Admission grade	Gender	Unemployment rat	Inflation rate	GDP	Target
1	0	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	0	9254	1	142.5	1	13.9	-0.3	0.79	Graduate
1	0	9130	6	120.0	0	12.4	0.5	1.79	Dropout
1	0	9773	1	119.6	0	9.4	-0.8	-3.12	Graduate
2	1	8014	1	141.5	0	13.9	-0.3	0.79	Graduate
1	0	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	0	9500	1	128.4	0	15.5	2.8	-4.06	Graduate
1	0	9254	1	113.1	1	15.5	2.8	-4.06	Dropout
1	0	9238	62	129.3	0	16.2	0.3	-0.92	Graduate
1	0	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	0	9670	1	130.6	0	13.9	-0.3	0.79	Graduate
1	0	9500	1	119.3	0	12.7	3.7	-1.7	Graduate
1	0	9238	26	132.5	0	13.9	-0.3	0.79	Graduate
1	0	9085	103	132.2	0	10.8	1.4	1.74	Graduate

Outliers

- Valores que estão além dos limites aceitáveis ou são muito diferentes dos demais (exceções)
 - Podem ser valores legítimos.



Transformação dos dados

- **Codificação de variáveis categóricas:** Modelos de aprendizado de máquina geralmente trabalham com números. Por isso, variáveis categóricas precisam ser transformadas.

```
azul      -> 1 0 0
verde     -> 0 1 0
vermelho  -> 0 0 1
```

- **Codificação ordinal:** Quando as categorias possuem ordem, podemos usar codificação ordinal.

```
baixo    -> 0
médio    -> 1
alto     -> 2
```

Conversão simbólico-numérico

- Atributo nominal com dois valores:

Marital status	Course	Nacionality	Admission grade	Gender	Unemployment rate	Inflation rate	GDP	Target
1	171	1	127.3	1	10.8	1.4	1.74	Dropout
1	9254	1	142.5	1	13.9	-0.3	0.79	Graduate
1	9130	6	120.0	0	12.4	0.5	1.79	Dropout
1	9773	1	119.6	0	9.4	-0.8	-3.12	Graduate
2	8014	1	141.5	0	13.9	-0.3	0.79	Graduate
2	9991	1	114.8	1	16.2	0.3	-0.92	Graduate
1	9500	1	128.4	0	15.5	2.8	-4.06	Graduate
1	9254	1	113.1	1	15.5	2.8	-4.06	Dropout
1	9238	62	129.3	0	16.2	0.3	-0.92	Graduate
1	9238	1	123.0	0	8.9	1.4	3.51	Dropout
1	9670	1	130.6	0	13.9	-0.3	0.79	Graduate
1	9500	1	119.3	0	12.7	3.7	-1.7	Graduate
1	9238	26	132.5	0	13.9	-0.3	0.79	Graduate
1	9085	103	132.2	0	10.8	1.4	1.74	Graduate
1	9556	103	183.5	0	16.2	0.3	-0.92	Dropout
1	9773	1	120.7	0	15.5	2.8	-4.06	Dropout

Conversão simbólico-numérico

- **Atributo nominal com mais valores**
 - Inexistência de relação de ordem deve ser mantida
 - Codificação canônica: uso de c bits para c valores
 - Cada posição na sequência binária corresponde a um valor possível do atributo nominal
 - Cada sequência possui apenas um bit com valor 1
 - Distância de Hamming entre quaisquer dois valores é 2

Conversão simbólico-numérico

- **Atributo ordinal com mais que dois valores**
 - Relação de ordem deve ser preservada
 - Ordenar valores ordinais e codificar cada um de acordo com sua posição na ordem com inteiro ou real

Atributo	Valor inteiro
Primeiro	1
Segundo	2
Terceiro	3
Quarto	4
Quinto	5
Sexto	6

```
baixo  -> 0  
médio -> 1  
alto   -> 2
```


Conversão simbólico-numérico

- Atributo ordinal com mais que dois valores
 - Se for necessário usar valores binários, pode ser utilizado:
 - **Código cinza:** correção de erros em comunicação
 - **Código termômetro:** aumento de valores se assemelha a aumento de temperatura em termômetro

Atributo	Código cinza	Código termômetro
Primeiro	000	00000
Segundo	001	00001
Terceiro	011	00011
Quarto	010	00111
Quinto	110	01111
Sexto	100	11111


Conversão simbólico-numérico

- One Hot Encoding




- **Atributo discreto e binário** $\Rightarrow$ conversão é trivial
 - Associa um nome a cada valor
 - Também se são sequências binárias sem relação de ordem
- **Demais casos: discretização**
 - Transforma valores numéricos em intervalos (categorias)
 - Existem vários métodos diferentes para discretização
 - Paramétricos: usuário pode influenciar definição dos intervalos
 - Não paramétricos: usam apenas informações presentes nos valores dos atributos

Discretização




Transformação de atributos numéricos

- Algumas vezes é necessário **transformar** o valor de um atributo numérico em outro valor numérico
 - Quando o intervalo de valores são muito diferentes, levando a grande variação
 - Quando vários atributos estão em escalas diferentes
 - Para evitar que um atributo predomine sobre outro



Transformação de atributos numéricos

- **Transformação** é aplicada aos valores de um dado atributo de todos os objetos.



$$x_{std}^{(i)} = \frac{x^{(i)} - \mu_x}{\sigma_x}$$

standardization

$$x_{norm}^{(i)} = \frac{x^{(i)} - \mathbf{x}_{min}}{\mathbf{x}_{max} - \mathbf{x}_{min}}$$


min-max scaling
("normalization")

	input	standardized	normalized
0	0	-1.46385	0.0
1	1	-0.87831	0.2
2	2	-0.29277	0.4
3	3	0.29277	0.6
4	4	0.87831	0.8
5	5	1.46385	1.0

Transformação de atributos numéricos


- Outro tipo de transformação: **tradução**
 - Valor é traduzido por um mais facilmente manipulável
 - Ex. converter data de nascimento para idade
 - Ex. converter temperatura de F para C
 - Ex. localização por GPS para código postal

$$\frac{\theta_C}{5} = \frac{\theta_F - 32}{9}$$







Transformação de atributos numéricos

- Outro tipo de transformação: aplicação de **função simples**
 - Aplicação a cada valor do atributo
 - Ex. log, exp, raiz, seno, $1/x$, abs
 - Ex. apenas magnitude dos valores é importante $\Rightarrow$ converter para valor absoluto
 - Funções raiz, log e $1/x$: aproximam uma distribuição Gaussiana
 - Função log: comprimir dados com grande intervalo de valores



Transformação de atributos numéricos



$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{if } \lambda \neq 0, \\ \ln(y_i) & \text{if } \lambda = 0, \end{cases}$$


Redução de dimensionalidade

- Muitos problemas possuem número elevado de atributos
 - Ex. reconhecimento de imagens
- Se cada pixel for considerado um atributo

Maldição da dimensionalidade

“O número de exemplos necessários para se aprender um certo conceito cresce exponencialmente de acordo com o número de atributos”

(Valiant, “A Theory of The Learnable”, 1984)



Redução de dimensionalidade

- Técnicas podem ser divididas em duas abordagens:

1 - Agregação


Combinação dos atributos originais por funções lineares ou não lineares

- Ex. PCA (*Principal Component Analysis*), que elimina redundâncias por correlação
- Levam à perda dos valores originais

2 - Seleção de atributos

- Identificar os atributos mais importantes
- Manter os relevantes
- Remover os redundantes e inconsistentes
- Diferentes critérios podem ser usados para medir importância

Redução de dimensionalidade



Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
1	5.1	3.5	1.4	0.2	Iris-setosa
2	4.9	3	1.4	0.2	Iris-setosa
3	4.7	3.2	1.3	0.2	Iris-setosa
4	4.6	3.1	1.5	0.2	Iris-setosa
5	5	3.6	1.4	0.2	Iris-setosa
6	5.4	3.9	1.7	0.4	Iris-setosa
7	4.6	3.4	1.4	0.3	Iris-setosa
8	5	3.4	1.5	0.2	Iris-setosa
9	4.4	2.9	1.4	0.2	Iris-setosa
10	4.9	3.1	1.5	0.1	Iris-setosa
11	5.4	3.7	1.5	0.2	Iris-setosa
12	4.8	3.4	1.6	0.2	Iris-setosa
13	4.8	3	1.4	0.1	Iris-setosa
14	4.3	3	1.1	0.1	Iris-setosa
15	5.8	4	1.2	0.2	Iris-setosa
16	5.7	4.4	1.5	0.4	Iris-setosa
17	5.4	3.9	1.3	0.4	Iris-setosa
18	5.1	3.5	1.4	0.3	Iris-setosa
19	5.7	3.8	1.7	0.3	Iris-setosa

