

Estatística descritiva


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

francisco@icmc.usp.br

Onde estamos?



Como caracterizar os dados?

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	age	workclass	fnlwgt	education	education_n	marital_status	occupation	relationship	race	sex	capital_gain	capital_loss	hours_per_wk	native_country	class	
2	25	Private	226802	11th	7	Never-married	Machine-op	Own-child	Black	Male	0	0	40	United-States	<= 50K.	
3	38	Private	89814	HS-grad	9	Married-divorced	Farming-fishing	Husband	White	Male	0	0	50	United-States	<= 50K.	
4	28	Local-gov	336951	Assoc-acad	12	Married-divorced	Protective-svc	Husband	White	Male	0	0	40	United-States	> 50K.	
5	44	Private	160323	Some-college	10	Married-divorced	Machine-op	Husband	Black	Male	7688	0	40	United-States	> 50K.	
6	34	Private	198693	10th	6	Never-married	Other-service	Not-in-family	White	Male	0	0	30	United-States	<= 50K.	
7	63	Self-employed-not-in-family	104626	Prof-school	15	Married-divorced	Prof-specialty	Husband	White	Male	3103	0	32	United-States	> 50K.	
8	24	Private	369667	Some-college	10	Never-married	Other-service	Unmarried	White	Female	0	0	40	United-States	<= 50K.	
9	55	Private	104996	7th-8th	4	Married-divorced	Craft-repair	Husband	White	Male	0	0	10	United-States	<= 50K.	
10	65	Private	184454	HS-grad	9	Married-divorced	Machine-op	Husband	White	Male	6418	0	40	United-States	> 50K.	
11	36	Federal-gov	212465	Bachelors	13	Married-divorced	Adm-clerical	Husband	White	Male	0	0	40	United-States	<= 50K.	
12	26	Private	82091	HS-grad	9	Never-married	Adm-clerical	Not-in-family	White	Female	0	0	39	United-States	<= 50K.	
13	48	Private	279724	HS-grad	9	Married-divorced	Machine-op	Husband	White	Male	3103	0	48	United-States	> 50K.	
14	43	Private	346189	Masters	14	Married-divorced	Exec-managerial	Husband	White	Male	0	0	50	United-States	> 50K.	
15	20	State-gov	444554	Some-college	10	Never-married	Other-service	Own-child	White	Male	0	0	25	United-States	<= 50K.	
16	43	Private	128354	HS-grad	9	Married-divorced	Adm-clerical	Wife	White	Female	0	0	30	United-States	<= 50K.	
17	37	Private	60548	HS-grad	9	Widowed	Machine-op	Unmarried	White	Female	0	0	20	United-States	<= 50K.	
18	34	Private	107914	Bachelors	13	Married-divorced	Tech-support	Husband	White	Male	0	0	47	United-States	> 50K.	
19	34	Private	238588	Some-college	10	Never-married	Other-service	Own-child	Black	Female	0	0	35	United-States	<= 50K.	
20	25	Private	220931	Bachelors	13	Never-married	Prof-specialty	Not-in-family	White	Male	0	0	43	Peru	<= 50K.	
21	25	Private	205947	Bachelors	13	Married-divorced	Prof-specialty	Husband	White	Male	0	0	40	United-States	<= 50K.	
22	45	Self-employed-not-in-family	432824	HS-grad	9	Married-divorced	Craft-repair	Husband	White	Male	7298	0	90	United-States	> 50K.	
23	22	Private	236427	HS-grad	9	Never-married	Adm-clerical	Own-child	White	Male	0	0	20	United-States	<= 50K.	
24	23	Private	134446	HS-grad	9	Separated	Machine-op	Unmarried	Black	Male	0	0	54	United-States	<= 50K.	
25	54	Private	99516	HS-grad	9	Married-divorced	Craft-repair	Husband	White	Male	0	0	35	United-States	<= 50K.	
26	32	Self-employed-not-in-family	109282	Some-college	10	Never-married	Prof-specialty	Not-in-family	White	Male	0	0	60	United-States	<= 50K.	
27	46	State-gov	106444	Some-college	10	Married-divorced	Exec-managerial	Husband	Black	Male	7688	0	38	United-States	> 50K.	
28	56	Self-employed-not-in-family	186651	11th	7	Widowed	Other-service	Unmarried	White	Female	0	0	50	United-States	<= 50K.	
29	24	Self-employed-not-in-family	188274	Bachelors	13	Never-married	Sales	Not-in-family	White	Male	0	0	50	United-States	<= 50K.	
30	23	Local-gov	258120	Some-college	10	Married-divorced	Protective-svc	Husband	White	Male	0	0	40	United-States	<= 50K.	
31	26	Private	43311	HS-grad	9	Divorced	Exec-managerial	Unmarried	White	Female	0	0	40	United-States	<= 50K.	
32	36	Local-gov	403681	Bachelors	13	Married-divorced	Prof-specialty	Husband	White	Male	0	0	40	United-States	> 50K.	
33	22	Private	248446	5th-6th	3	Never-married	Priv-house-par	Not-in-family	White	Male	0	0	50	Guatemala	<= 50K.	
34	17	Private	269430	10th	6	Never-married	Machine-op	Not-in-family	White	Male	0	0	40	United-States	<= 50K.	
35	20	Private	257509	HS-grad	9	Never-married	Craft-repair	Own-child	White	Male	0	0	40	United-States	<= 50K.	
36	65	Private	136384	Masters	14	Married-divorced	Prof-specialty	Husband	White	Male	0	0	50	United-States	> 50K.	
37	44	Self-employed-in-family	120277	Assoc-voc	11	Married-divorced	Sales	Husband	White	Male	0	0	45	United-States	> 50K.	
38	36	Private	465126	HS-grad	9	Married-divorced	Farming-fishing	Husband	White	Male	0	0	40	United-States	<= 50K.	
15056	48	Local-gov	349230	Masters	14	Divorced	Other-service	Not-in-family	White	Male	0	0	40	United-States	<= 50K.	
15057	33	Private	245211	Bachelors	13	Never-married	Prof-specialty	Own-child	White	Male	0	0	40	United-States	<= 50K.	
15058	39	Private	215419	Bachelors	13	Divorced	Prof-specialty	Not-in-family	White	Female	0	0	36	United-States	<= 50K.	
15059	38	Private	374983	Bachelors	13	Married-divorced	Prof-specialty	Husband	White	Male	0	0	50	United-States	<= 50K.	
15060	44	Private	83891	Bachelors	13	Divorced	Adm-clerical	Own-child	Asian-Pac-Islander	Male	5455	0	40	United-States	<= 50K.	
15061	35	Self-employed-not-in-family	182148	Bachelors	13	Married-divorced	Exec-managerial	Husband	White	Male	0	0	60	United-States	> 50K.	
15062																

Estatística Descritiva

Exploração dos dados

- Medida de Frequência.
- Medida centrais.
- Medidas de dispersão.
- Medidas de correlação.

Frequência


- Proporção de vezes que um atributo assume um dado valor.

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Baixa	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Média	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável


62,5% dos pacientes são homens

Frequência

- Gráfico de frequência





- Histograma



Frequência

- **Histograma:**
 - Não há um método geral para definir o tamanho da caixa.
 - Deve-se escolher de modo a não perder informação.



Moda

- Retorna o valor mais comum. Geralmente usada com dados nominais.

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Baixa	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Média	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

↗
Moda: SP

↗
Moda: M

↗
Moda: Baixa


Moda

Python

```
from statistics import mode
```

```
Y = ["red", "blue", "blue", "red", "green", "red", "red"]  
print('A moda de Y:', mode(Y))
```


A moda de Y: red



```
from statistics import mode
```



```
X = [1,2,3,4,1,2,4,5,4,5,7,8,9,0,1,1,2,3,1,2,3,1,4,5,6,7,8,7,6,4,4,4,1,4,4,4,5,6]  
print('A moda de X:', mode(X))
```

A moda de X: 4



Moda

Y = ["Bom", "Ruim", "Ótimo", "Regular", "Regular", "Ótimo", "Ótimo", "Bom",
"Ótimo", "Bom", "Ótimo"]



Média

$$\bar{X} = \sum_{i=1}^N \frac{X_i}{N}$$

Problema:

sensível a outliers
Bom indicador
apenas se valores
são distribuídos
simetricamente.

Identificação	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Baixa	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Média	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Média: 29,5

Média: 92,6

Mediana

- Passos:

- Ordenar os valores de forma crescente
- Calcular a equação:

$$mediana(\mathbf{x}) = \begin{cases} \frac{(X_r + X_{r+1})}{2} & \text{se } n \text{ for par } (n = 2r) \\ X_{r+1} & \text{se } n \text{ for ímpar } (n = 2r + 1) \end{cases}$$

ID	Nome	Estado	Idade	Sexo	Nível de Glicose	Febre	Dores no corpo	Diagnóstico
100	João	SP	22	M	90,5	Baixa	Não	Saudável
102	Maria	SP	39	F	86,5	Baixa	Não	Saudável
230	Rubens	RJ	23	M	120,2	Baixa	Sim	Doente
40	João	RS	21	M	85,9	Alta	Não	Doente
543	Marta	SP	40	F	88,7	Alta	Sim	Doente
12	Ana	AM	32	F	78,8	Média	Não	Saudável
130	Carlos	SP	29	M	110	Média	Sim	Doente
123	José	RJ	30	M	80,1	Baixa	Sim	Saudável

Média: 29,5
Mediana: 29,5

Média: 92,6
Mediana: 87,6


MedianaMediana

$$\text{Mediana}(\mathbf{X}) = \begin{cases} 1/2(X_r + X_{r+1}), & \text{se } n \text{ for par } (n = 2r) \\ X_{r+1}, & \text{se } n \text{ for ímpar } (n = 2r + 1), \end{cases}$$

- Exemplos:
 - {17, 4, 8, 21, 4}
 - Ordenando: 4, 4, 8, 17, 21
 - Número ímpar de elementos $\Rightarrow$ mediana = 8
 - {17, 4, 8, 21, 4, 15, 13, 9}
 - Ordenando: 4, 4, 8, 9, 13, 15, 17, 21
 - Número par de elementos $\Rightarrow$ mediana = $(9+13)/2 = 11$


Média X Mediana

Distribuição Normal



(a)

Distribuição Exponencial



(b)

Média —
Mediana - -

Média e Mediana

Python

```
import numpy as np
X = [1,1,1,2,2,3,4,5,5,5]
mx = np.mean(X)
print('X:', X)
print('A média:', mx)
```

```
X: [1, 1, 1, 2, 2, 3, 4, 5, 5, 5]
A média: 2.9
```

```
md = np.median(X)
print('X:', X)
print('A mediana:', md)
```

```
X: [1, 1, 1, 2, 2, 3, 4, 5, 5, 5]
A mediana: 2.5
```

```
X2 = [1,1,1,2,2,3,4,5,5,100]
print('X2:', X2)
print('A nova média:', np.mean(X2))
print('A nova mediana:', np.median(X2))
```

```
X2: [1, 1, 1, 2, 2, 3, 4, 5, 5, 100]
A nova média: 12.4
A nova mediana: 2.5
```

Quartil e percentil

Quartis


- Divide em quartos
 - 1º quartil ($Q1$) $\Rightarrow$ valor que tem 25% dos demais valores abaixo dele
 - 2º quartil ($Q2$) = mediana
 - 3º quartil ($Q3$) $\Rightarrow$ valor que tem 75% dos demais valores abaixo dele

Percentil

- Para p entre 0 e 100
- p percentil = $P_p \Rightarrow x_i$ tal que $p\%$ dos valores observados são menores do que x_i
- $P_{25} = Q1$
- $P_{50} = Q2 = \text{mediana}$



Quartil e percentil

$$X = \{9, 3, 11, 14, 20, 4, 6, 17, 30, 21, 23, 16\}$$



$$Q1 = 7,5, Q2 = 15 \text{ e } Q3 = 20,5$$

Boxplots



Medidas de dispersão

- Dois conjuntos de dados podem apresentar as mesmas medidas de posição.
- Por exemplo, os conjuntos $X = \{0,0,1,1,18\}$ e $Y = \{4,4,4,4,4\}$ possuem a mesma média igual a 4.
- Ou seja, se usarmos apenas a média para caracterizar os dados, vamos concluir que ambos são iguais.
- Medem **dispersão** ou **espalhamento** de um conjunto de valores
 - Permitem observar se valores estão:
 - Espalhados
 - Concentrados em torno de um valor (ex. da média)
 - Medidas mais comuns:
 - Variância
 - Desvio padrão
 - IQR

Medidas de dispersão

- **Variância**

$$\sigma^2 = E[(X - E(X))^2] = E[X^2] - E[X]^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

- **Desvio padrão:**

- População

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

- Amostra

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \mu)^2}$$

Estimador não-viesado.

Medidas de dispersão

- Exemplo: Sejam os vetores: $X = \{0, 0, 1, 1, 18\}$ e $Y = \{4, 4, 4, 4, 4\}$.

$$\mu = \frac{\sum_{i=1}^N x_i}{N} = 4$$

$$\sigma^2 = E[(X - E(X))^2] = E[X^2] - E[X]^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

$$\sigma_X^2 = \frac{(0-4)^2 + (0-4)^2 + (1-4)^2 + (1-4)^2 + (18-4)^2}{5-1} = 61,5$$

$$\sigma_Y^2 = \frac{(4-4)^2 + (4-4)^2 + (4-4)^2 + (4-4)^2 + (4-4)^2}{5-1} = 0$$

Medidas de dispersão

- Outras medidas de dispersão:

- Distância interquantil:

- $IQR = Q_3 - Q_1$

- Amplitude:



- $R(X) = \max(X) - \min(X)$

Ex:

$$X = \{9, 3, 11, 14, 20, 4, 6, 17, 30, 21, 23, 16\}$$

$$IQR = Q_3 - Q_1 = 20,5 - 7,5 = 13$$

$$R(X) = 30 - 3 = 27$$




```
from scipy.stats import iqr

def variancia(X):
    m = np.mean(X)
    N = len(X)
    s = 0
    for i in np.arange(0, len(X)):
        s = s + (X[i]-m)**2
    s = s/(N-1)
    return s

X = [0,0,1,1,18]
Y = [4, 4, 4, 4, 4]
mx = np.mean(X)
my = np.mean(Y)
print('X:', X)
print('Média de X:', mx)
print('Variância de X:', variancia(X))
print('IQR de X:', iqr(X))
print('Amplitude de X:', np.max(X)-np.min(X))

print('\n')
print('Y:', Y)
print('Média de Y:', my)
print('Variância de Y:', variancia(Y))
print('IQR de Y:', iqr(Y))
print('Amplitude de Y:', np.max(Y)-np.min(Y))
```

```
X: [0, 0, 1, 1, 18]
Média de X: 4.0
Variância de X: 61.5
IQR de X: 1.0
Amplitude de X: 18
```

```
Y: [4, 4, 4, 4, 4]
Média de Y: 4.0
Variância de Y: 0.0
IQR de Y: 0.0
Amplitude de Y: 0
```

Notem que os dados acima possuem a mesma média, mas a variância é bastante diferente.

Coeficiente de variação

- É uma medida de dispersão relativa, expressando a variabilidade em relação à média.

$$CV = \frac{\sigma_X}{\bar{X}} \times 100, \quad \bar{X} \neq 0$$


	Média	Desvio Padrão	CV
Altura	1,143 m	0,063 m	5,5%
Peso	50 Kg	6 Kg	12%

- Conclusão: O peso dos alunos apresenta variabilidade relativa duas vezes maior do que a altura.

Análise multivariada



Relação entre variáveis

El Niño - Southern Oscillation





Time series of SSTs in the East Pacific (region Nino3.4)

ENSO dominant mode of global climate variability on interannual time scales





- Gráfico de dispersão (scatterplot):

```
X = [-2.25230219  0.17488531  0.86807664  1.57008988 -0.8529788 ]  
Y = [-1.23335724 -0.50329834 -0.16286028 -0.63108853  0.36720953]
```




Visualização

- Três variáveis:




- Gráficos espaciais:



Visualização

- Grafos:



Como medir a relação entre as variáveis?

Medidas de correlação

- **Coeficiente de Pearson:**

- Para duas variáveis aleatórias X e Y :


$$\rho_{X,Y} = \frac{E[XY] - E[X]E[Y]}{\sqrt{E[X^2] - [E[X]]^2} \sqrt{E[Y^2] - [E[Y]]^2}} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

- Para uma amostra:


$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}$$

Medidas de correlação

- Coeficiente de Pearson:




Medidas de correlação



Medidas de correlação

- Interpretação:


$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$



Medidas de correlação

```
import pandas as pd # biblioteca pandas
data = pd.read_csv('data/iris.csv', header=(0)) # lê os dados a partir do arquivo

corr = data.corr()
#Plot Correlation Matrix using Matplotlib
plt.figure(figsize=(7, 5))
plt.imshow(corr, cmap='Blues', interpolation='none', aspect='auto')
plt.colorbar()
plt.xticks(range(len(corr)), corr.columns, rotation='vertical')
plt.yticks(range(len(corr)), corr.columns);
plt.suptitle('Correlation between variables', fontsize=15, fontweight='bold')
plt.grid(False)
plt.show()
```



Correlação de Spearman

- **Coeficiente de Spearman:**

- A correlação de Spearman é igual ao coeficiente de Pearson aplicado aos valores da ordem de duas variáveis.

$$\rho = \frac{\sum_{i=1}^n (rx_i - \bar{rx})(ry_i - \bar{ry})}{\sqrt{\sum_{i=1}^n (rx_i - \bar{rx})^2} \cdot \sqrt{\sum_{i=1}^n (ry_i - \bar{ry})^2}}$$

- Por exemplo, se $X = \{3, 5, 1, 9, 6\}$ temos $rx = \{2, 3, 1, 5, 4\}$.

Correlação de Spearman


- **Coeficiente de Spearman:**
 - Avalia a relação monotônica entre duas variáveis contínuas ou ordinais e não é sensível a assimetrias na distribuição, nem à presença de outliers, já que consideramos a ordem e não os valores da variáveis.
 - Em uma relação monotônica, as variáveis tendem a mudar juntas mas não necessariamente a uma taxa constante.
 - Notem que enquanto a correlação de Pearson mede relações lineares, a de Spearman mede apenas relações monotônicas (lineares ou não- lineares).
 - Limitação: Quando temos muitas observações com a mesma ordem.

Spearman X Pearson

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import pearsonr, spearmanr


N = 100
x = np.linspace(1, 50000, N)
z = np.log(x)

plt.plot(x, z)
plt.xlabel("x", fontsize = 20)
plt.ylabel("Log(X)", fontsize = 20)
corr, p_value = pearsonr(x, z)
corrs, p_values = spearmanr(x, z)
corr = int(corr*100)/100
corrs = int(corrs*100)/100
string = 'Pearson corr. = ' + str(corr)
plt.text(20000, 3, string, fontsize=15)
string = 'Spearman corr. = ' + str(corrs)
plt.text(20000, 1, string, fontsize=15)
plt.show()
```




Correlação X Causalidade

Correlação não implica em causalidade!!!



Correlação X Causalidade


Correlação não implica em causalidade!!!



Correlação X Causalidade

Correlação não implica em causalidade!!!



The Real Cause of Polio!



- In the 1940s Polio example, public health experts recommended that people stop eating ice cream as part of an "anti-polio diet".

Correlação X Causalidade

Correlação não implica em causalidade!!!



Leitura adicional



Journal of Statistical Software


August 2014, Volume 59, Issue 10.

<http://www.jstatsoft.org/>

Tidy Data

Hadley Wickham
RStudio

<https://vita.had.co.nz/papers/tidy-data.pdf>



<https://datapot.vn/wp-content/uploads/2023/12/datapot.vn-Practical-Statistics-for-Data-Scientists.pdf?srltid=AfmBOorJ-IAS27vcKcVICxpZGeeqo8LCQzP5c7k4RdCPqJM7FVbANTcR>

