

Modelos de Regressão


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação


Universidade de São Paulo

francisco@icmc.usp.br

Modelos de regressão



Modelos de regressão



Valor do teste do PISA versus a renda per capita para diversos países (dados de 2012). A linha reta representa o modelo de regressão ajustado. Conhecendo-se a renda per capita (x_j) de um país j , podemos prever a sua nota no Pisa ($\hat{y}_j$) usando o modelo de regressão.

Modelos de regressão

Aprendizado = Representação + Avaliação + Otimização

- Representação (como é o modelo),
- Avaliação (como diferenciamos os modelos bons dos ruins),
- Otimização (qual é o nosso processo para encontrar os modelos bons entre todos os modelos possíveis).

Modelos de regressão

Aprendizado = Representação + Avaliação + Otimização


- No caso da regressão linear:
 - A representação do nosso modelo é uma função linear.
 - A métrica de avaliação pode ser o erro quadrático médio.
 - O método de otimização pode ser a descida do gradiente.

Modelos de regressão

Aprendizado = Representação + Avaliação + Otimização

Representation	Evaluation	Optimization
Instances	Accuracy/Error rate	Combinatorial optimization
K-nearest neighbor	Precision and recall	Greedy search
Support vector machines	Squared error	Beam search
Hyperplanes	Likelihood	Branch-and-bound
Naive Bayes	Posterior probability	Continuous optimization
Logistic regression	Information gain	Unconstrained
Decision trees	K-L divergence	Gradient descent
Sets of rules	Cost/Utility	Conjugate gradient
Propositional rules	Margin	Quasi-Newton methods
Logic programs		Constrained
Neural networks		Linear programming
Graphical models		Quadratic programming
Bayesian networks		
Conditional random fields		

Modelos de regressão



$$\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\}$$

n	x_n	y_n
1	0.6700	3.0237
2	0.3474	2.3937
3	0.6695	3.5548
$\vdots$	$\vdots$	$\vdots$
$N - 1$	0.2953	2.6396
N	0.6804	3.2536

- O objetivo do ajuste dos mínimos quadrados (ou regressão linear) é encontrar uma linha que melhor se ajuste ao conjunto de dados.

$$y_i = ax_i + b$$

Modelos de regressão

- Para ajustarmos o modelo de regressão usando o método dos mínimos quadrados, consideramos os dados coletados, que constituem os pares $[(x_i, y_i), i = 1, 2, \dots, n]$, sendo que y_i depende de x_i através de uma relação linear.
- O nosso objetivo é estimar a reta que melhor se ajusta aos dados. Esse ajuste é dado por:


$$\hat{y}_i = \hat{\theta}_0 + \hat{\theta}_1 x_i \quad i = 1, 2, \dots, n,$$

- sendo $\hat{y}_i$ o valor predito e $\hat{\theta}_0$ e $\hat{\theta}_1$ os valores a serem ajustados a partir dos dados.

Modelos de regressão

- Para encontrar $\hat{\theta}_0$ e $\hat{\theta}_1$, precisamos definir um critério que quantifique o quão preciso é um ajuste.
- Para isso, vamos considerar um conceito importante chamado resíduo, que é igual à diferença entre o valor observado (y_i) e o predito ($\hat{y}_i$), isto é

$$e_i = y_i - \hat{y}_i, \quad i = 1, 2, \dots, n.$$



Modelos de regressão

- O método dos mínimos quadrados objetiva minimizar a soma dos quadrados dos resíduos, ou seja, determinar a reta que melhor se aproxima dos dados. Portanto, o conceito de "melhor ajuste" se traduz em encontrar a reta que produz o menor erro, quantificado pelo resíduo.
- A soma dos quadrados dos resíduos (*residual sum of squares* (**RSS**), em inglês) é dada por:

$$\text{RSS} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\theta}_0 - \hat{\theta}_1 x_i)^2.$$

Modelos de regressão

- Para minimizar esse erro, ou seja, encontrar o mínimo de RSS, derivamos essa equação com relação a $\hat{\theta}_0$ e $\hat{\theta}_1$ e igualamos os resultados a zero.

$$\begin{cases} \frac{\partial \text{RSS}}{\partial \hat{\theta}_0} = -2 \sum_{i=1}^n (y_i - \hat{\theta}_0 - \hat{\theta}_1 x_i) = 0, \\ \frac{\partial \text{RSS}}{\partial \hat{\theta}_1} = -2 \sum_{i=1}^n (y_i - \hat{\theta}_0 - \hat{\theta}_1 x_i) x_i = 0. \end{cases}$$

Modelos de regressão

- Resolvendo para $\hat{\theta}_0$ e $\hat{\theta}_1$, obtemos:

$$\hat{\theta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}.$$

- onde $\bar{y} = \sum_{i=1}^n y_i/n$ e $\bar{x} = \sum_{i=1}^n x_i/n$.

Modelos de regressão


```
import matplotlib.pyplot as plt
%matplotlib inline
import numpy as np
from statistics import variance
import math as math

def estimate_coef(x, y):
    n = np.size(x) # number of observations
    m_x, m_y = np.mean(x), np.mean(y) #mean values
    S_xy = 0
    S_xx = 0
    # calculate the covariance and variance
    for i in range(0, len(x)):
        S_xy = S_xy + (x[i]-m_x)*(y[i]-m_y)
        S_xx = S_xx + (x[i]-m_x)**2
    #determine the coefficients
    b_1 = S_xy / S_xx
    b_0 = m_y - b_1*m_x
    return(b_0, b_1)

# data
x = np.array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
y = np.array([1, 3, 2, 5, 7, 8, 8, 9, 10, 12])

b = estimate_coef(x, y)
# perform the prediction
y_pred = b[0] + b[1]*x
# plot the data points
plt.scatter(x, y, color = "b", marker = "o", s = 50)
# show the adjusted model
plt.plot(x, y_pred, color = "black")
plt.xlabel('x', fontsize = 15)
```

$$\hat{\theta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}.$$




Modelos de regressão

- Método dos mínimos quadrados

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$



Modelos de regressão

- Em aprendizado de máquina:
- Dados os pontos $(x_1, y_1), \dots, (x_N, y_N)$ a regressão consiste no processo de determinar o parâmetro θ de uma função $g_\theta(\cdot)$ de modo que a função de custo de treinamento seja minimizada:

$$\hat{\theta} = \arg \min_{\theta \in \mathbb{R}^d} \underbrace{\frac{1}{N} \sum_{n=1}^N \mathcal{L}(y_n, g_\theta(x_n))}_{\text{custo de treinamento } \mathcal{E}_{\text{treino}}(\theta)} .$$

- Aqui, $\mathcal{L}(\cdot, \cdot)$ representa a perda entre o valor observado verdadeiro y_n e a predição do modelo $g_\theta(x_n)$.

Modelos de regressão

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta} \in \mathbb{R}^d} \underbrace{\frac{1}{N} \sum_{n=1}^N \mathcal{L}(y_n, g_{\boldsymbol{\theta}}(x_n))}_{\text{custo de treinamento } \mathcal{E}_{\text{treino}}(\boldsymbol{\theta})} .$$

$$\hat{\boldsymbol{\theta}} = \arg \min_{\boldsymbol{\theta} \in \mathbb{R}^d} \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y_n, g_{\boldsymbol{\theta}}(x_n)) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Modelos de regressão

- Python...

Modelos de regressão

- **Análise Estatística:**
- Variável resposta (ou dependente): Y ,
- Variável preditora (ou independente): X .
- Em outras palavras, buscamos entender como a variável Y se relaciona com a variável X por meio de uma equação linear.
- Assim, dado um conjunto de observações de X , nosso objetivo é estimar a função de regressão $f(x)$, que representa a expectativa condicional de Y dado que $X = x$:


$$f(x) = \mathbb{E}[Y \mid X = x] = \theta_0 + \theta_1 x.$$

Modelos de regressão

- O modelo de regressão linear simples é definido por:

$$Y_i = \theta_0 + \theta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n.$$

- onde assumimos $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$.
- Os parâmetros θ_1 e θ_0 são fixos e desconhecidos.



Modelos de regressão

- Como o modelo é linear e ϵ_i tem distribuição normal, então Y_i também segue o modelo normal:

$$Y_i \sim \mathcal{N}(\theta_0 + \theta_1 x_i, \sigma^2).$$

- Assim,

$$p(y_i | x_i, \theta_0, \theta_1) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2\sigma^2} (\theta_0 + \theta_1 x_i - y_i)^2 \right).$$

Modelos de regressão

- Para inferirmos os valores de θ_0 e θ_1 , consideramos o problema:

$$\hat{\theta} = \operatorname{argmax}_{\theta} L(\theta; \mathbf{x}),$$

- onde $\theta^T = [\theta_0, \theta_1]$ e $\hat{\theta}^T = [\hat{\theta}_0, \hat{\theta}_1]$.
- Ou seja, precisamos encontrar os valores $\hat{\theta}_0$ e $\hat{\theta}_1$ de forma a maximizar a função de verossimilhança $L(\theta; \mathbf{x})$.

Modelos de regressão

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n p(y_i | x_i, \theta).$$

$$\log L(\theta; \mathbf{x}) = \sum_{i=1}^n \log p(y_i | x_i, \theta).$$

$$\begin{aligned} \log L(\theta; \mathbf{x}) &= \sum_{i=1}^n \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2\sigma^2} (\theta^T x_i - y_i)^2 \right) \right] \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (\theta^T x_i - y_i)^2. \end{aligned}$$

Modelos de regressão

- Ignorando os termos que não dependem de θ , pois não influenciam na maximização da verossimilhança, podemos escrever:

$$\begin{aligned}\hat{\theta} &= \operatorname{argmax}_{\theta} \log L(\theta; \mathbf{x}) \\ &= \operatorname{argmax}_{\theta} \left[- \sum_{i=1}^n (\theta^T x_i - y_i)^2 \right] \\ &= \operatorname{argmin}_{\theta} \sum_{i=1}^n (\theta^T x_i - y_i)^2 \\ &= \operatorname{argmin}_{\theta} \sum_{i=1}^n (\theta_0 + \theta_1 x_i - y_i)^2\end{aligned}$$

Modelos de regressão

- Portanto, a estimação por máxima verossimilhança resulta no método dos mínimos quadrados:

$$\hat{\theta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x}.$$

- onde $\bar{y} = \sum_{i=1}^n y_i/n$ e $\bar{x} = \sum_{i=1}^n x_i/n$.


Modelos de regressão

- Inferência sobre os parâmetros:

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2)$$

$$Y_i \sim \mathcal{N}(\beta_0 + \beta_1 X_i, \sigma^2)$$

$$\begin{aligned} E[\hat{\beta}_1] &= E \left[\frac{\text{Cov}(X, Y)}{V(X)} \right] \\ &= E \left[\frac{E[(X - E(X))(Y - E(Y))]}{V(X)} \right] \\ &= E \left[\frac{E[(X - E(X))(\beta_0 + \beta_1 X - E(Y))]}{V(X)} \right] \\ &= E \left[\frac{E[\beta_0 X + \beta_1 X^2 - XE[Y] - \beta_0 E[X] - \beta_1 E[X]X + E[X]E[Y]]}{V(X)} \right] \\ &= \frac{\beta_0 E[X] + \beta_1 E[X^2] - E[X]E[Y] - \beta_0 E[X] - \beta_1 E[X]^2 + E[X]E[Y]}{E[X^2] - E[X]^2} \\ &= \beta_1 \end{aligned}$$



$$E[\hat{\beta}_0] = \beta_0$$


Modelos de regressão

- Inferência sobre os parâmetros:

$$Y_i \sim \mathcal{N}(\beta_0 + \beta_1 X_i, \sigma^2)$$

$$\hat{\beta}_0 \sim \mathcal{N}\left(\beta_0, \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$



- O estimador de $V(\epsilon) = \sigma^2$

$$S_\epsilon^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$


Modelos de regressão

- Intervalo de confiança:

$$Y_i \sim \mathcal{N}(\beta_0 + \beta_1 X_i, \sigma^2)$$

$$IC(\beta_0; \alpha) = \hat{\beta}_0 \pm t_{\alpha/2, n-2} \frac{S_\epsilon \sqrt{\sum_{i=1}^n x_i^2}}{\sqrt{n \sum_{i=1}^n (x_i - \bar{x})^2}}$$

$$IC(\beta_1; \alpha) = \hat{\beta}_1 \pm t_{\alpha/2, n-2} \frac{S_\epsilon}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}}$$



$$S_\epsilon^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

Modelos de regressão

- No caso do teste de hipóteses, geralmente consideramos as seguintes hipóteses para o coeficiente de inclinação:

$$H_0 : \theta_1 = 0$$

$$H_1 : \theta_1 \neq 0.$$

- quando a hipótese nula não é rejeitada, a conclusão é que não há uma relação linear entre Y e a variável independente X , isto é, $\theta_1 = 0$.

Modelos de regressão

- **Teste de hipóteses:**

- H_0 : Não há relação entre X e Y .
- H_a : Há alguma relação entre X e Y .

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$H_0 : \beta_1 = 0$$

$$H_a : \beta_1 \neq 0$$

Modelos de regressão

- **Exemplo:**
- Uma empresa está interessada em determinar quanto o tempo de exposição na televisão ajuda no aumento das vendas.
- São coletados dados do volume de recursos gastos com exposição na TV e vendas.
- A partir desses dados, podemos analisar como a campanha publicitária influencia nas vendas.

James et al., Introduction to statistical learning with applications in R, 2014.

Modelos de regressão

- Há alguma relação entre os recursos e vendas?
- Se houver, quão forte é essa relação?
- Se houver dados de outras mídias, como essas mídias influenciam nas vendas?
- Qual delas mais influencia?
- Podemos estimar o volume de vendas através dos recursos gastos?
- Quão acurada pode ser a previsão de vendas no futuro?

Modelos de regressão

$$Y \approx \beta_0 + \beta_1 X$$


Intercepto

Inclinação

Parâmetros do modelo

- Para o exemplo anterior:

$$Vendas \approx \beta_0 + \beta_1 TV$$



Modelos de regressão


- Para estimar os parâmetros (coeficientes) do modelo, usamos o conjunto de treinamento.
- O modelo ajustado é representado por:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- Que permite determinar estimativas de Y.
- A acurácia do modelo é verificada no conjunto de teste.

Modelos de regressão

- Para realizar a regressão, vamos minimizar o erro em relação à reta estimada.




Modelos de regressão

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$




Modelos de regressão

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$\hat{\beta}_0 = 7,03 \quad \hat{\beta}_1 = 0,0475$$

A cada 1000 dólares gastos com o anúncio na TV, vende-se aproximadamente 47,5 unidades do produto.




Modelos de regressão

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad 0 \leq R^2 \leq 1$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$R^2 = 0,61$, indicando que a variável TV explica apenas 2/3 da variabilidade nas vendas.



Modelos de regressão

- No exemplo anterior, rejeitamos a hipótese nula, ou seja, há uma relação entre o investimento em anúncios na TV e número de itens vendidos.

$$Vendas \approx \beta_0 + \beta_1 TV$$

	Coefficient	Std. error	t-statistic	p-value
Intercept	7.0325	0.4578	15.36	< 0.0001
TV	0.0475	0.0027	17.67	< 0.0001


James et al., Introduction to statistical learning with applications in R, 2014.

Modelos de regressão

- Python...

Modelos de regressão

Leitura adicional



<https://probability4datascience.com>