

Modelos de Regressão Multivariada

Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

francisco@icmc.usp.br

Regressão multivariada

- Modelos de regressão podem ser usados principalmente para duas tarefas:
- Prever dados desconhecidos a partir do modelo treinado.
- Determinar a importância de cada variável independente na previsão.
- O modelo de regressão linear é um dos mais comumente usados:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_d X_d$$

Variável
resposta (saída)

Variáveis independentes (covariáveis)

Modelos de regressão

- Um modelo de regressão com k variáveis preditoras $\{X_1, X_2, \dots, X_k\}$ e apenas uma saída Y_j é definido por

$$Y_j = \theta_0 + \theta_1 x_{j1} + \theta_2 x_{j2} + \dots + \theta_k x_{jk} + \epsilon_j, \quad j = 1, 2, \dots, n,$$

- onde a variável ϵ_j representa o erro na predição, que geralmente tem distribuição normal com média igual a zero e variância σ^2 .
- Notem que o modelo é linear com relação aos parâmetros $\theta_0, \dots, \theta_k$.


Modelos de regressão

$$Y_j = \theta_0 + \theta_1 x_{j1} + \theta_2 x_{j2} + \dots + \theta_k x_{jk} + \epsilon_j, \quad j = 1, 2, \dots, n,$$

- Os termos de erro apresentam as seguintes propriedades:
 - $E[\epsilon_j] = 0$, para $j = 1, \dots, n$
 - $Var(\epsilon_j) = \sigma^2$
 - $Cov(\epsilon_i, \epsilon_j) = 0$ para $i, j = 1, \dots, n; i \neq j$

Modelos de regressão


$$Y_j = \theta_0 + \theta_1 x_{j1} + \theta_2 x_{j2} + \dots + \theta_k x_{jk} + \epsilon_j, \quad j = 1, 2, \dots, n,$$



Modelos de regressão

- Na maioria dos casos, estamos interessados na influência de várias variáveis em uma variável alvo.

$$Y \approx \beta_0 + \beta_1 X_1 + \beta_2 X_2$$



- Por exemplo, podemos analisar o efeito do investimento em TV, rádio e jornal na quantidade de itens vendidos, ao invés de considerar apenas TV.

Modelos de regressão

- Suponha que temos d preditores distintos para a variável Y . Então, o modelo de regressão linear múltipla é:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_d X_d$$

- No exemplo:

$$\text{Vendas} = \beta_0 + \beta_1 \text{TV} + \beta_2 \text{Radio} + \beta_3 \text{Jornal}$$

- Importante: o modelo é linear nos parâmetros e não nas variáveis, que podem ser não lineares (ex. X^2 , $\text{sen}(X)$, $\ln(X)$).

Modelos de regressão


- Queremos inferir o modelo:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_d x_d$$

- Usando o mesmo método que anteriormente, objetivamos minimizar o erro:

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2$$

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_d x_{id})^2$$



Modelos de regressão

- Usando notação matricial:

$$y = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_d x_{id} + \epsilon$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

$$\begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix}_{n \times 1} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1d} \\ 1 & x_{21} & x_{22} & \dots & x_{2d} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix}_{n \times d} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_d \end{pmatrix}_{d \times 1} + \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \dots \\ \epsilon_n \end{pmatrix}_{n \times 1}$$

- Queremos minimizar a soma dos quadrados dos resíduos:

$$\text{RSS} = \boldsymbol{\epsilon}^T \boldsymbol{\epsilon} = \sum_{i=1}^N \epsilon_i^2$$

Modelos de regressão

- Minimizando o erro: $RSS = \epsilon^T \epsilon = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$

$$RSS = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta$$

- Assim:

$$\frac{\partial RSS}{\partial \beta^T} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = 0$$

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$$

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T \mathbf{y}$$

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Modelos de regressão

$$\boldsymbol{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- $\mathbf{X}^T \mathbf{X}$ deve ser positiva definida.

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1d} \\ 1 & x_{21} & x_{22} & \dots & x_{2d} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix} \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_d \end{pmatrix}$$

Inversa de Moore-Penrose $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$

Modelos de regressão

- Exemplo:

$$\text{Vendas} = \beta_o + \beta_1 \text{TV} + \beta_2 \text{Radio} + \beta_3 \text{Jornal}$$

	Coefficient	Std. error	t-statistic	p-value
Intercept	2.939	0.3119	9.42	< 0.0001
TV	0.046	0.0014	32.81	< 0.0001
radio	0.189	0.0086	21.89	< 0.0001
newspaper	-0.001	0.0059	-0.18	0.8599

Modelos de regressão

Interpretação:


- Quando falamos em **importância dos atributos** em regressão (ou em qualquer modelo preditivo), estamos querendo saber quais variáveis (atributos) têm maior influência sobre a variável resposta.
- No contexto da regressão linear múltipla, isso se relaciona diretamente com os coeficientes.
- **Quanto maior o valor absoluto do coeficiente β_j , maior o efeito de uma unidade de mudança em X_j sobre Y .**
 - **Limitação:** não dá para comparar diretamente se as variáveis têm escalas diferentes.
 - **Solução:** padronizar os atributos (também chamado de z-score), ou seja: $X_j^{(pad)} = (X_j - \bar{X}_j) / \sigma_{X_j}$

Modelos de regressão

Regressão polinomial

- Importante: Notem que o modelo não precisa ter termos lineares em X , mas apenas nos parâmetros:

Ainda é um
modelo
linear!



$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon$$

Modelos de regressão

Regressão polinomial

- **Ideia geral:** Basta fazermos $X_i = X^i$ no modelo de regressão multivariado:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \dots + \hat{\beta}_d x^d$$



$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_d x_d$$

- **Exemplo:** Dados gerados usando o modelo:

$$Y = x^4 + \epsilon$$

- Modelo ajustado:

$$Y = \beta_0 + \beta_1 X^4$$



Modelos de regressão

Generalização

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

$$g_{\boldsymbol{\theta}}(x_n) = \sum_{p=0}^{d-1} \theta_p \phi_p(x_n).$$

$$\underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}}_{\mathbf{y}} = \underbrace{\begin{bmatrix} \phi_0(x_1) & \phi_1(x_1) & \cdots & \phi_{d-1}(x_1) \\ \phi_0(x_2) & \phi_1(x_2) & \cdots & \phi_{d-1}(x_2) \\ \vdots & \cdots & \vdots & \vdots \\ \phi_0(x_N) & \phi_1(x_N) & \cdots & \phi_{d-1}(x_N) \end{bmatrix}}_{\mathbf{X}} \underbrace{\begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_{d-1} \end{bmatrix}}_{\boldsymbol{\theta}} + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{bmatrix}}_{\mathbf{e}}.$$

Modelos de regressão

Generalização

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

- Regressão linear

$$\underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}}_{\mathbf{y}} = \underbrace{\begin{bmatrix} \phi_0(x_1) & \phi_1(x_1) & \cdots & \phi_{d-1}(x_1) \\ \phi_0(x_2) & \phi_1(x_2) & \cdots & \phi_{d-1}(x_2) \\ \vdots & \cdots & \vdots & \vdots \\ \phi_0(x_N) & \phi_1(x_N) & \cdots & \phi_{d-1}(x_N) \end{bmatrix}}_{\mathbf{X}} \underbrace{\begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_{d-1} \end{bmatrix}}_{\boldsymbol{\theta}} + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{bmatrix}}_{\mathbf{e}}.$$



$$y = \theta_0 + \theta_1 x_{i1} + \theta_2 x_{i2} + \dots + \theta_d x_{id} + \epsilon$$

$$\begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix}_{n \times 1} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1d} \\ 1 & x_{21} & x_{22} & \dots & x_{2d} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix}_{n \times d} \begin{pmatrix} \theta_0 \\ \theta_1 \\ \dots \\ \theta_d \end{pmatrix}_{d \times 1} + \begin{pmatrix} \epsilon_0 \\ \epsilon_1 \\ \dots \\ \epsilon_n \end{pmatrix}_{n \times 1}$$

Modelos de regressão

Generalização

$$g_{\boldsymbol{\theta}}(x_n) = \sum_{p=0}^{d-1} \theta_p x^p,$$

- Regressão Polinomial

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} 1 & x_1 & \cdots & x_1^{d-1} \\ 1 & x_2 & \cdots & x_2^{d-1} \\ \vdots & \cdots & \vdots & \vdots \\ 1 & x_N & \cdots & x_N^{d-1} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_{d-1} \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_N \end{bmatrix},$$

$$\mathbf{y} = \mathbf{X}\boldsymbol{\theta} + \mathbf{e}.$$

Modelos de regressão

- **Exemplo:** Dados gerados usando o modelo:

$$Y = 5 + 2X_1 + 3X_2 + \epsilon$$

- Modelo ajustado:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$$



- Intervalo de confiança

$$2,828 < \beta_0 < 5,615$$

$$1,832 < \beta_1 < 2,138$$

$$3,054 < \beta_2 < 3,350$$

$$-0,188 < \beta_3 < 0,146.$$




- Valor p:

$$p(\beta_0) = p(\beta_1) = p(\beta_2) = 0; p(\beta_3) = 0,85$$


Modelos de regressão

1. Bom modelo
(pressupostos atendidos)




✓ Resíduos aleatórios em torno de zero e com variância constante.

2. Não linearidade
(relação não capturada pelo modelo)




✗ Padrão curvo: o modelo linear não está capturando a relação. Considere adicionar termos não lineares (ex.: polinômios, splines).

3. Heterocedasticidade
(variância não constante)




✗ A variância dos resíduos aumenta (ou diminui) com os valores ajustados. Pode violar o pressuposto de homocedasticidade.

4. Outliers
(observações atípicas)




✗ Resíduos muito grandes (positivos ou negativos) podem indicar outliers ou observações influentes que distorcem o modelo.

5. Dependência (não independência)
(padrão ou tendência)



✗ Padrões ou tendências indicam que os resíduos não são independentes. Pode ocorrer em dados temporais ou ordenados.


6. Assimetria (não normalidade)
(distribuição dos resíduos)



✗ Resíduos assimétricos ou com caudas longas podem indicar que o erro não é normalmente distribuído.

Modelos de regressão

Leitura adicional



<https://probability4datascience.com>