

Árvore de decisão


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação


Universidade de São Paulo

francisco@icmc.usp.br

Árvore de decisão





Árvore de decisão



```
if x_2 < 3.0 then
  return Blue
else
  if x_1 < 5.0 then
    return Blue
  else
    return Red
  end
end
```


Árvore de decisão




```
if x_2 < 3.0 then
  return Blue
else
  if x_1 < 5.0 then
    return Blue
  else
    return Red
  end
end
```

Árvore de decisão

Estrutura da árvore:


- **Nós folha (resposta):** contém uma previsão.
- **Nós internos:**
 - Contém um teste de atributo.
 - Para cada possível valor do atributo, existe um ramo para outra sub-árvore.




Árvore de decisão



Árvore de decisão




Árvore de decisão



Árvore de decisão



Classificação:

- Depois de construída a árvore, a classificação é feita “navegando” pela árvore até chegar a um nó folha.




Árvore de decisão

Regressão



Árvore de decisão

- Métodos baseados em árvores dividem o espaço de atributos em regiões.
- Em cada região, é estimada a função $p(y | \mathbf{x})$.
- As regras para dividir o espaço podem ser resumidas em uma árvore, denominada árvore de decisão.



Árvore de decisão

- Matematicamente, a árvore modela as probabilidades $p(k | \mathbf{x})$ como uma constante C_{mk} em cada região R_m , para $k = 1, 2, \dots, K$.

$$p(y = k | \mathbf{x}) = \sum_{m=1}^M C_{mk} I\{\mathbf{x} \in R_m\},$$

onde

$$\sum_{k=1}^K C_{mk} = 1$$

- O objetivo é encontrar uma árvore que gere os dados observados, no conjunto de treinamento, com maior probabilidade possível.
- Esse método considera a maximização da verossimilhança.

Árvore de decisão

- A maximização da verossimilhança:

$$p(y = k | \mathbf{x}) = \sum_{m=1}^M c_{mk} I\{\mathbf{x} \in R_m\},$$

$$-\log \ell(T) = -\log p(\mathbf{y} | \mathbf{X}, T)$$

- A maximização dessa função é um problema combinatorial e computacionalmente proibitivo.
- **Solução: usar um algoritmo de recursão binária.**


Como construir a árvore?

- Considerar os dados de treinamento e tentar prevê-los com maior acurácia possível.
- Devemos definir uma métrica para encontrar os ramos e escolher os nós da árvore.
- Há diferente métricas para realizar essa tarefa e o resultado pode depender dessa escolha.

Árvore de decisão

Como construir a árvore?

- Existem vários algoritmos
 - Algoritmo de Hunt
 - CART
 - ID3, C4.5
 - SLIQ, SPRINT



Algoritmo de Hunt:

- O algoritmo de Hunt é um dos primeiros e mais fundamentais algoritmos para a construção de árvores de decisão.
- Ele forma a base de métodos como ID3, C4.5 e CART.
- O algoritmo segue um processo recursivo de divisão do espaço de atributos até que critérios de parada sejam satisfeitos.

Árvore de decisão

Passos do Algoritmo de Hunt

- 1. Se todos os dados pertencem à mesma classe
 - O conjunto tem Maçãs e Peras, então não podemos parar ainda.

Peso (g)	Cor	Fruta
150	Vermelha	Maçã
170	Vermelha	Maçã
140	Verde	Maçã
130	Verde	Pera
120	Verde	Pera

Árvore de decisão

Passos do Algoritmo de Hunt

1. Se todos os dados pertencem à mesma classe
 - O conjunto tem Maçãs e Peras, então não podemos parar ainda.
2. Escolhemos o melhor atributo para dividir
 - Podemos dividir os dados por cor ou peso.
 - Atributo escolhido: Cor (pois separa melhor as classes).


Peso (g)	Cor	Fruta
150	Vermelha	Maçã
170	Vermelha	Maçã
140	Verde	Maçã
130	Verde	Pera
120	Verde	Pera

Árvore de decisão

Passos do Algoritmo de Hunt

1. Se todos os dados pertencem à mesma classe
 - O conjunto tem Maçãs e Peras, então não podemos parar ainda.
2. Escolhemos o melhor atributo para dividir
 - Podemos dividir os dados por cor ou peso.
 - Atributo escolhido: Cor (pois separa melhor as classes).
3. Criamos os nós com base na cor:
 - Se a fruta é vermelha, então é Maçã (pois todas as vermelhas são maçãs).
 - Se a fruta é verde, ainda temos Maçãs e Peras, então precisamos dividir mais.

Peso (g)	Cor	Fruta
150	Vermelha	Maçã
170	Vermelha	Maçã
140	Verde	Maçã
130	Verde	Pera
120	Verde	Pera




Árvore de decisão

Passos do Algoritmo de Hunt

3. Criamos os nós com base na cor:
- Se a fruta é vermelha, então é Maçã (pois todas as vermelhas são maçãs).
 - Se a fruta é verde, ainda temos Maçãs e Peras, então precisamos dividir mais.

Peso (g)	Cor	Fruta
150	Vermelha	Maçã
170	Vermelha	Maçã
140	Verde	Maçã
130	Verde	Pera
120	Verde	Pera




Árvore de decisão

Passos do Algoritmo de Hunt

3. Criamos os nós com base na cor:
- Se a fruta é vermelha, então é Maçã (pois todas as vermelhas são maçãs).
 - Se a fruta é verde, ainda temos Maçãs e Peras, então precisamos dividir mais.
4. Dividimos as frutas verdes pelo peso
- Se o peso $\geq 140g$, então Maçã.
 - Se o peso $< 140g$, então Pera.

Peso (g)	Cor	Fruta
150	Vermelha	Maçã
170	Vermelha	Maçã
140	Verde	Maçã
130	Verde	Pera
120	Verde	Pera




Árvore de decisão

Emprego	Estado Civil	Renda	Crédito
Sim	Solteiro	9500	Sim
Não	Casado	8000	Não
Não	Solteiro	7000	Não
Sim	Casado	12000	Sim
Não	Divorciado	9000	Sim
Não	Casado	6000	Não
Sim	Divorciado	4000	Sim
Não	Solteiro	8500	Sim
Não	Casado	7500	Não
Não	Divorciado	8000	Não


Árvore de decisão

Emprego	Estado Civil	Renda	Crédito
Sim	Solteiro	9500	Sim
Não	Casado	8000	Não
Não	Solteiro	7000	Não
Sim	Casado	12000	Sim
Não	Divorciado	9000	Sim
Não	Casado	6000	Não
Sim	Divorciado	4000	Sim
Não	Solteiro	8500	Sim
Não	Casado	7500	Não
Não	Divorciado	8000	Não




Árvore de decisão

Emprego	Estado Civil	Renda	Crédito
Sim	Solteiro	9500	Sim
Não	Casado	8000	Não
Não	Solteiro	7000	Não
Sim	Casado	12000	Sim
Não	Divorciado	9000	Sim
Não	Casado	6000	Não
Sim	Divorciado	4000	Sim
Não	Solteiro	8500	Sim
Não	Casado	7500	Não
Não	Divorciado	8000	Não



Árvore de decisão

Emprego	Estado Civil	Renda	Crédito
Sim	Solteiro	9500	Sim
Não	Casado	8000	Não
Não	Solteiro	7000	Não
Sim	Casado	12000	Sim
Não	Divorciado	9000	Sim
Não	Casado	6000	Não
Sim	Divorciado	4000	Sim
Não	Solteiro	8500	Sim
Não	Casado	7500	Não
Não	Divorciado	8000	Não




Árvore de decisão

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set


Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Test Set



Árvore de decisão

Aplicação:




Conjunto de teste

Emprego	Estado Civil	Renda	Crédito
Não	Solteiro	8100	?

Árvore de decisão

Aplicação:



Conjunto de teste


Emprego	Estado Civil	Renda	Crédito
Não	Solteiro	8100	?

Árvore de decisão

Aplicação:

Conjunto de teste


Emprego	Estado Civil	Renda	Crédito
Não	Solteiro	8100	?



Árvore de decisão

Aplicação:


Conjunto de teste



Emprego	Estado Civil	Renda	Crédito
Não	Solteiro	8100	?

Árvore de decisão

Aplicação:




Conjunto de teste

Emprego	Estado Civil	Renda	Crédito
Não	Solteiro	8100	SIM

Classificação: “Sim”


Árvore de decisão

- Como construir a árvore?




Árvore de decisão

- Como construir a árvore?




Árvore de decisão



- Como construir a árvore?





Árvore de decisão



Árvore de decisão



Árvore de decisão



Árvore de decisão


- Como construir a árvore?
 - Construir uma árvore minimal (número mínimo de nós) condizente com conjunto de dados é problema NP-completo.
 - Algoritmos usualmente usam heurísticas que olham um passo à frente.
 - Estratégia gulosa.
 - Suscetível a encontrar ótimo local.
 - Mas permite construção da árvore em tempo linear.

Árvore de decisão

- Como construir a árvore?
 - **Decisões importantes**
 - Como dividir os objetos?


Tipo de carro

Esporte
Família
Luxo




Refrigerante

Pequeno
Médio
Grande
Gigante




Árvore de decisão

- **Como construir a árvore?**
 - **Decisões importantes**
 - Medida para avaliar qualidade de atributo escolhido.



Árvore de decisão

- Como construir a árvore?
 - Decisões importantes
 - Quando parar de dividir os objetos.




Árvore de decisão

- Como construir a árvore?

- Estratégia gulosa:

- Precisamos de uma medida para selecionarmos entre duas (ou mais) divisões.



Qual é a melhor opção?

Árvore de decisão

- **Como construir a árvore?**

- **Estratégia gulosa:**

- Medida de pureza: mede o quão homogênea é a distribuição dos elementos das classes com relação à um atributo:

C0: 5
C1: 5

Não-homogênea
Alto grau de impureza

C0: 9
C1: 1

Homogênea
Baixo grau de impureza

- Índice de Gini
- Entropia
- Erro na classificação

Árvore de decisão

Índice de Gini:

$$\text{Gini}(t) = 1 - \sum_{j=0}^{c-1} [p(j | t)]^2$$

- $p(j | t)$ representa a frequência de elementos da classe j no nó t .

C1	0
C2	6

$P(C1) = 0/6 = 0 \quad P(C2) = 6/6 = 1$
 $\text{Gini} = 1 - P(C1)^2 - P(C2)^2 = 1 - 0 - 1 = 0$

C1	2
C2	4

$P(C1) = 2/6 \quad P(C2) = 4/6$
 $\text{Gini} = 1 - (2/6)^2 - (4/6)^2 = 0.444$

Entropia de Shannon:

$$H(t) = - \sum_{j=0}^{c-1} p(j | t) \log_2 p(j | t)$$

- $p(j | t)$ representa a frequência de elementos da classe j no nó t .

C1	0
C2	6

$P(C1) = 0/6 = 0$ $P(C2) = 6/6 = 1$
 $H = -(0/6 * \log_2(0/6) + 1 * \log_2(1)) = 0$

C1	2
C2	4

$P(C1) = 2/6$ $P(C2) = 4/6$
 $Gini = -(2/6 * \log_2(2/6) + 4/6 * \log_2(4/6)) = 0.92$

Árvore de decisão

Erro na classificação:

$$\text{Erro}(t) = 1 - \max_i [p(i | t)]$$

- $p(j | t)$ representa a frequência de elementos da classe j no nó t .

C1	0
C2	6

$$P(C1) = 0/6 = 0 \quad P(C2) = 6/6 = 1$$


$$\text{Erro} = 1 - 1 = 0$$

C1	2
C2	4

$$P(C1) = 2/6 \quad P(C2) = 4/6$$

$$\text{Erro} = 1 - 4/6 = 2/6 = 0.33$$

Árvore de decisão



Árvore de decisão

- Mas como decidir se paramos uma divisão ou continuamos a crescer a árvore?
- Precisamos decidir quando aceitamos um novo ramo ou inserimos um nó folha.
- Para isso, comparamos o grau de impureza do nó pai (antes da divisão) com o do nó filho (após a divisão).
- Quanto maior essa diferença, melhor é a divisão.

Árvore de decisão

A medida de ganho:

$$\Delta = I(\text{pai}) - \sum_{i=1}^k \frac{N(v_i)}{N} I(v_i),$$

- onde
 - $I(.)$ é uma medida de impureza de um dado nó,
 - N é o número total de elementos no nó pai
 - k é o número de atributos
 - $N(v_i)$ é o número de elementos associado ao nó filho v_i .

Quanto maior o ganho, melhor é a divisão.

Árvore de decisão

A medida de ganho:


$$\Delta = I(\text{pai}) - \sum_{i=1}^k \frac{N(v_i)}{N} I(v_i),$$

onde

- $I(.)$ é uma medida de impureza de um dado nó,
 - N é o número total de elementos no nó pai
 - k é o número de atributos
 - $N(v_i)$ é o número de elementos associado ao nó filho v_i .
-
- Escolha a partição que resultar no maior ganho.
 - Usado nos algoritmos ID3 e C4.5
 - Tente a gerar muitas partições, pequenas, mas puras.

Árvore de decisão

Ganho de informação:




- Antes da divisão, temos 5 pontos azuis e 5 vermelhos:

$$H(t) = - \sum_{j=0}^{c-1} p(j | t) \log_2 p(j | t)$$

$$H(\text{pai}) = - 0,5 \log_2(0,5) - 0,5 \log_2(0,5) = 1$$

Árvore de decisão

Ganho de informação:



- 4 azuis
- 5 vermelhos e 1 azul

- Depois da divisão:

$$\Delta_{\text{info}} = H(\text{pai}) - \sum_{i=1}^k \frac{N(v_i)}{N} H(i)$$
$$-\left(\frac{1}{6} \log_2\left(\frac{1}{6}\right) + \frac{5}{6} \log_2\left(\frac{5}{6}\right)\right)$$

$$\Delta_{\text{info}} = 1 - (0,4 \times 0 + 0,6 \times 0,65) = 0,61$$

Entropia é nula, pois todos os círculos são azuis.

Árvore de decisão

- **Ganho de informação:**
 - Tente a gerar muitas partições, pequenas, mas puras.
- **Razão de ganho (Gain ratio):**

$$G = \frac{\Delta_{\text{info}}}{-\sum_{i=1}^k \frac{N(v_i)}{N} \log_2 \frac{N(v_i)}{N}}$$

- Usado para solucionar a limitação do ganho de informação.
- Usado no algoritmo C4.5.

Árvore de decisão

Índice de Gini:

- Quando um nó j é dividido em k partições (filhos), a qualidade dessa divisão é calculada por:

$$\text{Gini}_{split} = \sum_{i=1}^k \frac{N(v_i)}{N} \text{Gini}(i)$$

$N(v_i)$ = número de entradas no nó filho.

N = número de entradas no nó pai.

- Se houver redução no índice, aceitamos a divisão.
- Usado nos algoritmos CART, SLIQ, SPRINT.

Escolha do nós raiz

ID	Renda	Idade	Estado Civil	Crédito (classe)
1	Alta	≥ 30	Casado	Classe 1
2	Baixa	≥ 30	Casado	Classe 1
3	Baixa	< 30	Casado	Classe 2
4	Baixa	< 30	Solteiro	Classe 2
5	Baixa	≥ 30	Solteiro	Classe 3
6	Alta	≥ 30	Solteiro	Classe 3
7	Alta	< 30	Casado	Classe 3

Distribuição das classes no conjunto todo

Classe 1 = 2, Classe 2 = 2, Classe 3 = 3 (Total = 7)

Entropia do conjunto (S):

$$H(S) = - \sum_i p_i \log_2(p_i)$$
$$= - \left(\frac{2}{7} \log_2 \frac{2}{7} + \frac{2}{7} \log_2 \frac{2}{7} + \frac{3}{7} \log_2 \frac{3}{7} \right) = 1,557$$

Entropia máxima para 3 classes:

$$H(S) = -3 \left(\frac{1}{3} \log_2 \frac{1}{3} \right) = \log_2 3 \approx 1,585$$

2.1 Atributo: Idade

Valor	Classe 1	Classe 2	Classe 3	Total	Entropia
≥ 30	2	0	2	4	1,000
< 30	0	2	1	3	0,918

Entropia condicional:

$$H(S|Idade) = \frac{4}{7} (1,000) + \frac{3}{7} (0,918) = 0,965$$

Ganho de Informação (Idade):

$$IG(S, Idade) = 1,557 - 0,965 = 0,592$$

2.2 Atributo: Renda

Valor	Classe 1	Classe 2	Classe 3	Total	Entropia
Alta	1	0	2	3	0,918
Baixa	1	2	1	4	1,500

Entropia condicional:

$$H(S|Renda) = \frac{3}{7} (0,918) + \frac{4}{7} (1,500) = 1,244$$

Ganho de Informação (Renda):

$$IG(S, Rende) = 1,557 - 1,244 = 0,313$$

2.3 Atributo: Estado Civil


Valor	Classe 1	Classe 2	Classe 3	Total	Entropia
Casado	2	1	2	5	1,522
Solteiro	0	1	1	2	1,000

Entropia condicional:

$$H(S|Estado Civil) = \frac{5}{7} (1,522) + \frac{2}{7} (1,000) = 1,373$$

Ganho de Informação (Estado Civil):

$$IG(S, Estado Civil) = 1,557 - 1,373 = 0,184$$



Árvore de decisão

Propriedades

- Simples entendimento e interpretação.
- Não requer normalização dos dados.
- Pode ser usada com dados numéricos e categóricos ao mesmo tempo.
- É um modelo “caixa branca”.
- É um método robusto a outliers.
- Pode ser usado em grandes bancos de dados.
- É um método não-paramétrico.

Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists
<http://smlbook.org/>

