

Seleção e ajuste de modelos


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação


Universidade de São Paulo

francisco@icmc.usp.br


Onde estamos?



Aprendizado supervisionado



Aprendizado supervisionado




Aprendizado supervisionado

- Muitos problemas em aprendizado de máquina consideram os mesmos ingredientes:
 1. O primeiro ingrediente é um conjunto de dados $D=(\mathbf{X},\mathbf{y})$, onde $\mathbf{X}$ é uma matrix de variáveis independentes e $\mathbf{y}$ é o vetor de variáveis dependentes.
 2. O segundo ingrediente é modelo $f(\mathbf{x}, \theta)$, onde f é uma função $f: \mathbf{x} \rightarrow y$ dos parâmetros θ .
 3. O terceiro ingrediente é a função custo $C(\mathbf{y}, f(\mathbf{X}; \theta))$ que permite determinar o quanto o modelo f é adequado para predizer $\mathbf{y}$.

Aprendizado supervisionado

- Por exemplo:


1. $D(\mathbf{X}, \mathbf{y})$



2. Modelo $f(\mathbf{x}, \theta) = \sum_{j=0}^M \theta_j x^j$

3. Função custo

$$E(\theta) = \sqrt{\frac{1}{N} \sum_{n=1}^N \{f(x_n, \theta) - y_n\}^2}$$




Modelos preditivos

- O modelo é ajustado encontrando os valores de θ que minimizam a função custo.
- Uma pergunta básicas e refere ao ajuste dos parâmetros do modelo:
- Quais os melhores valores dos parâmetro de forma a oferecer uma boa generalização e prever dados futuros com precisão?


$$\hat{\theta} = \arg \min_{\theta} \underbrace{\frac{1}{n} \sum_{i=1}^n \overbrace{L(\hat{y}(\mathbf{x}_i; \theta), y_i)}^{\text{loss function}}}_{\text{cost function } J(\theta)}.$$

$$L(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2$$



Regressão polinomial

- Vamos considerar um exemplo:
- Os dados foram gerados a partir da função:




$$y = \sin(2\pi x) + \epsilon$$

- Onde ϵ tem distribuição uniforme com média zero e desvio padrão σ .
- Vamos supor que temos acesso apenas aos pontos em azul e não conhecemos a curva original.

Regressão polinomial

- Vamos considerar algumas possíveis curvas para modelar os dados:




$$f(\mathbf{x}, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_M x_M = \sum_{j=0}^M \theta_j x^j$$

$$E_{RMS} = E(\theta) = \frac{1}{2} \sum_{n=1}^N \{f(x_n, \theta) - y_n\}^2$$

Regressão polinomial


$$f(\mathbf{x}, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_M x_M = \sum_{i=0}^M \theta_j x^j$$




N = 10 observações

<https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>


Complexidade do modelo



Overfitting




Overfitting: Ocorre quando um modelo se ajusta muito bem ao conjunto de dados anteriormente observado, mas se mostra ineficaz para prever novos resultados. O modelo está super adaptando aos dados de treinamento.




- Nesse exemplo, temos 10 pontos e um polinômios de grau 9. O modelo está super adaptado aos dados de treinamento.

Overfitting




$N = 10$ observações





- Quando aumentamos a complexidade do modelo, ocorre um super ajuste.

Overfitting

$N = 10$ observações




$N = 15$ observações




$N = 100$ observações

Overfitting


- Regressão



Underfitted
(High bias error)




Good Fit/Robust
(Balance between
bias and variance)



Overfitted
(High variance error)

Overfitting


- Classificação







Overfitting

- Ocorre por três motivos:
 1. Número o exemplos no conjunto de treinamento.
 2. Complexidade do modelo.
 3. Variância do ruído:
$$y_n = f(X) + \epsilon, \quad \langle \epsilon \rangle = 0, \quad V(\epsilon) = \sigma^2$$

Viés-variância (bias-variance)



Structural risk minimization



Bias-variance decomposition

$$\begin{aligned}\text{Error} &= \text{Irreducible Error} + \text{Reducible Error} \\ &= \text{Irreducible Error} + (\text{Bias Error} + \text{Variance Error}).\end{aligned}$$


$$MSE = E \left[(y - \hat{f}(x))^2 \right]$$

$$E \left[(y - \hat{f}(x))^2 \right] = E \left[((f(x) + \epsilon) - \hat{f}(x))^2 \right] = E \left[((f(x) - \hat{f}(x)) + \epsilon)^2 \right]$$

$$\begin{aligned}E \left[((f(x) - \hat{f}(x)) + \epsilon)^2 \right] &= E \left[(f(x) - \hat{f}(x))^2 \right] + 2E \left[(f(x) - \hat{f}(x)) \epsilon \right] + E[\epsilon^2] \\ &= E \left[(f(x) - \hat{f}(x))^2 \right] + 2E \left[(f(x) - \hat{f}(x)) \right] \underbrace{E[\epsilon]}_{=0} + \underbrace{E[\epsilon^2]}_{=\sigma^2} \\ &= \underbrace{E \left[(f(x) - \hat{f}(x))^2 \right]}_{\text{reducible error}} + \underbrace{\sigma^2}_{\text{irreducible error}}\end{aligned}$$

Bias-variance decomposition

$$E\left[\left((f(x) - \hat{f}(x)) + \varepsilon\right)^2\right] = \underbrace{E\left[\left(f(x) - \hat{f}(x)\right)^2\right]}_{\text{reducible error}} + \underbrace{\sigma^2}_{\text{irreducible error}}$$


$$E\left[\left(f(x) - \hat{f}(x)\right)^2\right] = E\left[\left((f(x) - E[\hat{f}(x)]) - (\hat{f}(x) - E[\hat{f}(x)])\right)^2\right]$$

$$\begin{aligned} & E\left[\left((f(x) - E[\hat{f}(x)]) - (\hat{f}(x) - E[\hat{f}(x)])\right)^2\right] \\ &= \underbrace{E\left[\left(f(x) - E[\hat{f}(x)]\right)^2\right]}_{\text{Bias}(\hat{f}(x))^2} + \underbrace{E\left[\left(\hat{f}(x) - E[\hat{f}(x)]\right)^2\right]}_{\text{Var}(\hat{f}(x))} - 2E\left[\left(f(x) - E[\hat{f}(x)]\right) \cdot \left(\hat{f}(x) - E[\hat{f}(x)]\right)\right] \\ &= \text{Bias}(\hat{f}(x))^2 + \text{Var}(\hat{f}(x)) - 2(f(x) - E[\hat{f}(x)]) \cdot \underbrace{\left(E[\hat{f}(x)] - E[\hat{f}(x)]\right)}_{=0} \\ &= \text{Bias}(\hat{f}(x))^2 + \text{Var}(\hat{f}(x)) \end{aligned}$$




Bias-variance decomposition

$$MSE = \underbrace{E \left[(f(x) - \hat{f}(x))^2 \right]}_{\text{reducible error}} + \underbrace{\sigma^2}_{\text{irreducible error}}$$

$$= \text{Bias}(\hat{f}(x))^2 + \text{Var}(\hat{f}(x)) + \sigma^2$$

$$\underbrace{E \left[(f(x) - E[\hat{f}(x)])^2 \right]}_{\text{Bias}(\hat{f}(x))^2}$$

$$\underbrace{E \left[(\hat{f}(x) - E[\hat{f}(x)])^2 \right]}_{\text{Var}(\hat{f}(x))}$$



Objetivo: Baixo viés e baixa variância.


Dados versus complexidade



<https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>



Escolha dos modelos

N = 10 observações




$$f(\mathbf{x}, \theta) = \theta_0 + \theta_1 x_1 + \dots + \theta_9 x_9$$

N = 15 observações




N = 100 observações

Curva de aprendizado



- À medida que N cresce, tanto o erro de treinamento quanto o erro de teste convergem. Isso se deve à lei dos grandes números, que diz que os erros empíricos de treinamento e teste devem convergir para seus respectivos valores esperados.
- Se o erro de treinamento e o erro de teste convergirem para o mesmo valor, o treinamento poderá ser generalizado para o teste.

Curva de aprendizado



- Geralmente, assumimos que as amostras de treinamento e as amostras de teste são extraídas da mesma distribuição e, portanto, as amostras de treinamento são boas representantes das amostras de teste.
- Se a suposição não for verdadeira, haverá uma lacuna entre o erro de treinamento convergente e o erro de teste. Assim, o que afirmamos no treinamento não pode ser transferido para o teste.
- Consequentemente, a curva de aprendizado fornece uma ferramenta de depuração útil para verificar a comparação entre o treinamento e o teste.

Escolha do modelo

- Escolhendo o melhor modelo envolve a redução da variância e viés.
- Infelizmente: não há nenhum método científico padrão para isso.
- Como escolher complexidade ótima e conseguir erro mínimo no conjunto de teste?
- Erro no treinamento não é uma boa estimativa do erro no conjunto de teste.
- Podemos usar:
 - Validação hold out
 - K-fold cross validation

Selecionando o modelo

When we have a variety of models of different complexity (e.g., linear or logistic regression models with different degree polynomials, or KNN classifiers with different values of K), how should we pick the right one?

— Page 22, [Machine Learning: A Probabilistic Perspective](#), 2012.

Model selection is the process of choosing one of the models as the final model that addresses the problem.

No free lunch theorem

The no free lunch theorem for machine learning states that, averaged over all possible data-generating distributions, every classification algorithm has the same error rate when classifying previously unobserved points. (Wolpert, 1996)

There is no universal machine learning algorithm.


No free lunch theorem

O objetivo dos métodos de aprendizado de máquina é encontrar um algoritmo que seja adequado ao problema que está sendo estudado.

There is no universal machine learning algorithm.


No free lunch theorem

É importante comparar diferentes métodos para um dado problema.




Ajuste de modelos

- Erro no treinamento não é uma boa estimativa do erro no conjunto de teste.




Validação cruzada




Permite que cada observação apareça no conjunto de treinamento e teste. Usa todos os dados!

k=1: Leave-One-Out


Validação cruzada




Validação cruzada



Caso estratificado



Class Distributions



Fold 1

Fold 2


Fold 3

Fold 4

Fold 5

Manter a distribuição das classes em cada fold.

"Finding a good model involves trading off fit and complexity." Wasserman, All of Statistics.



Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists
<http://smlbook.org/>
- James et al., Introduction to statistical learning with applications in R, 2014.

