

Regularização de modelos


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação


Universidade de São Paulo

francisco@icmc.usp.br


Onde estamos?



Overfitting



$N = 10$ observações




- Quando aumentamos a complexidade do modelo, ocorre um super ajuste.

Simplificando Modelos via Regularização

Regularização

- Nos modelos de regressão, pode ocorrer *overfitting*:



$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \epsilon$$

- Polinômio de grau 4 para 5 pontos!

Regularização

- Uma das maneiras de evitar overfitting é usar regularização.
- Um dos métodos mais populares é chamada **Ridge Regression** (ou Tikhonov regularization).
- O critério de mínimos quadrados é modificado:

$$\underset{\beta_0, \beta_1, \dots, \beta_p}{\text{minimize}} \quad \|\mathbf{X}\boldsymbol{\beta} - \mathbf{y}\|_2^2 + \gamma \|\boldsymbol{\beta}\|_2^2.$$

- Onde $\gamma \geq 0$ é o parâmetro de regularização.
- Para $\gamma = 0$, temos o caso sem regularização.
- Se $\gamma \rightarrow \infty$, os parâmetros se aproximam de zero.

$$\|\boldsymbol{\beta}\|_p = \left(\sum_{i=1}^n |\beta_i|^p \right)^{1/p}$$



Regularização

- Resolvendo o modelo, como anteriormente, obtemos as equações normais:

$$(\mathbf{X}^T \mathbf{X} + \gamma I_{p+1}) \hat{\boldsymbol{\beta}} = \mathbf{X}^T \mathbf{y},$$

- E a solução:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X} + \gamma I_{d+1})^{-1} \mathbf{X}^T \mathbf{y}.$$



Regularização

- Outro método bastante popular é chamado o Least Absolute Shrinkage and Selection Operator (ou **LASSO**).
- Nesse caso, o critério de mínimos quadrados será:

$$\underset{\beta_0, \beta_1, \dots, \beta_p}{\text{minimize}} \quad \|\mathbf{X}\boldsymbol{\beta} - \mathbf{y}\|_2^2 + \gamma \|\boldsymbol{\beta}\|_1,$$

- Nesse caso, não há uma solução analítica e métodos de otimização devem ser usados.
- Para $\gamma = 0$, temos o caso sem regularização.
- Se $\gamma \rightarrow \infty$, os parâmetros se aproximam de zero.


$$\|\boldsymbol{\beta}\|_p = \left(\sum_{i=1}^n |\beta_i|^p \right)^{1/p}$$

Regularização


- Notem que os resultados obtidos por ridge regression e Lasso são diferentes.
- Enquanto ridge regression mantém os valores dos parâmetros $\beta_0, \beta_1, \dots, \beta_d$ pequenos, LASSO tendem a selecionar alguns valores para serem diferentes de zero, enquanto que outros são exatamente iguais a zero.
- Assim, LASSO pode ser usado para selecionar atributos.

Regularização


Regressão linear



Ridge regression



Lasso



Regularização

- Outros métodos podem ser definidos para regularização.
- De maneira geral, a função objetivo pode ser definidas por:

$$\underset{\beta}{\text{minimize}} \quad \underbrace{V(\beta, \mathbf{X}, \mathbf{y})}_{\text{data fit}} + \gamma \underbrace{R(\beta)}_{\substack{\text{model} \\ \text{flexibility} \\ \text{penalty}}} .$$

- Temos um termo que descreve o quão bem o modelo se ajusta aos dados.
- Um termo que penaliza a complexidade do modelo.
- A regularização é obtida através de um balanço entre esses dois termos.

Elastic Net

- A **Elastic Net** é uma técnica de regularização utilizada em modelos de regressão, especialmente em problemas com muitas variáveis explicativas ou quando há forte correlação entre elas. Essa abordagem combina duas penalizações clássicas: a penalização L_1 usada no Lasso, e a penalização L_2 , usada na regressão Ridge.
- A função objetivo da Elastic Net pode ser escrita como:

$$\min_{\beta} \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right] \right\},$$

em que y_i representa o valor observado, $\hat{y}_i$ é o valor predito pelo modelo, β_j são os coeficientes associados às variáveis explicativas, n é o número de observações e p é o número de variáveis.

Elastic Net

$$\min_{\beta} \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right] \right\},$$

- O parâmetro $\lambda \geq 0$ controla a intensidade da regularização.
- Quanto maior o valor de λ , maior será a penalização imposta aos coeficientes do modelo.
- Já o parâmetro $\alpha \in [0,1]$ controla a combinação entre as penalizações L_1 e L_2 .
- A principal vantagem da Elastic Net é combinar as propriedades do Lasso e da Ridge.

Regularização

- **Evita overfitting:** A regularização ajuda os modelos a se concentrarem nos padrões subjacentes dos dados, em vez de memorizar ruídos presentes no conjunto de treinamento.
- **Melhora o desempenho:** Ao evitar que outliers ou atributos irrelevantes recebam pesos excessivos, a regularização contribui para melhorar a acurácia geral do modelo.
- **Estabiliza os modelos:** Reduz a sensibilidade a pequenas variações nos dados, garantindo maior consistência entre diferentes subconjuntos de dados.

Regularização

- **Evita complexidade excessiva:** Impede que o modelo se torne excessivamente complexo, o que é especialmente importante quando os dados são limitados ou ruidosos.
- **Lida com multicolinearidade:** Reduz a magnitude dos coeficientes correlacionados, contribuindo para melhorar a estabilidade do modelo.
- **Promove consistência:** Garante um desempenho mais confiável em diferentes conjuntos de dados, reduzindo o risco de grandes variações de desempenho.

Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists
<http://smlbook.org/>
- James et al., Introduction to statistical learning with applications in R, 2014.

