

Classificadores probabilísticos

Francisco Rodrigues


Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

francisco@icmc.usp.br

Classificadores probabilísticos

Teorema de Bayes



"Probabilidade é uma opinião metódica e inferência de dados nada mais é do que a revisão de tal opinião com novas informações relevantes."



Thomas Bayes (1701 – 1761)



Pierre-Simon Laplace (1749-1827)

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{\sum_j P(A | B_j)P(B_j)}, \quad i = 1, 2, \dots$$

Classificadores probabilísticos

Decisão Bayesiana

Imaginem que uma fábrica produz peças que podem ser defeituosas ou perfeitas.

90% das peças são perfeitas.
10% são defeituosas.

Senso comum:

Classificar como perfeita, pois é a classe mais provável.




Uma nova peça é produzida.



**Defeituosa
ou perfeita?**

Teoria da decisão Bayesiana


- $P(C_1 | x)$: probabilidade da observação com atributos x pertencer à classe C_1 .
- $P(C_2 | x)$: probabilidade da observação com atributos x pertencer à classe C_2 .



Teoria da decisão Bayesiana

Se $P(C_1 | x) > P(C_2 | x)$ então classifique $x \in C_1$

Se $P(C_2 | x) > P(C_1 | x)$ então classifique $x \in C_2$



Teoria da decisão Bayesiana


Problema: Classificar em uma das m classes $C_1, C_2, \dots, C_m$ um vetor de característica $\mathbf{x}$, estimando as probabilidades a posteriori:

$$P(C_i | \mathbf{x}), \quad i = 1, 2, \dots, m$$


Para isso, vamos usar o teorema de Bayes.

Teoria da decisão Bayesiana

- Vamos considerar duas classes.
- Se $P(C_1 | x) > P(C_2 | x)$
então classifique $x \in C_1$
- Se $P(C_2 | x) > P(C_1 | x)$
então classifique $x \in C_2$




Teoria da decisão Bayesiana




- As probabilidades a priori podem ser estimadas dos dados:
- $P(C_1) = \frac{n_1}{n_1 + n_2}$
- $P(C_2) = \frac{n_2}{n_1 + n_2}$
- Vamos estimar a função de verossimilhança:
- $P(x | C_i), i = 1, 2$

Teoria da decisão Bayesiana



- Assim:
- $$P(C_j | x) = \frac{p(x | C_j)P(C_j)}{p(x)}, \quad j = 1, 2$$
- Se $P(C_1 | x) > P(C_2 | x)$ então
classifique $x \in C_1$
- Se $P(C_2 | x) > P(C_1 | x)$ então
classifique $x \in C_2$


Teoria da decisão Bayesiana



- Se $P(C_1 | x) > P(C_2 | x)$ então classifique $x \in C_1$
- Se $P(C_2 | x) > P(C_1 | x)$ então classifique $x \in C_2$
- Erro associado à classificação:
- $p_e = \min[P(C_1), P(C_2)]$.

Classificadores probabilísticos


$$p_e = p(x \in R_2, C_1) + p(x \in R_1, C_2) = p(x \in R_2 | C_1)P(C_1) + p(x \in R_1 | C_2)P(C_2).$$



$$p_e = \frac{1}{2} \int_{-\infty}^{x_0} p(x | C_2) dx + \frac{1}{2} \int_{x_0}^{\infty} p(x | C_1) dx.$$

Classificadores probabilísticos


$$p_e = p(x \in R_2, C_1) + p(x \in R_1, C_2) = p(x \in R_2 | C_1)P(C_1) + p(x \in R_1 | C_2)P(C_2).$$



$$p_e = \frac{1}{2} \int_{-\infty}^{x_0} p(x | C_2) dx + \frac{1}{2} \int_{x_0}^{\infty} p(x | C_1) dx.$$

$$p_e = P(C_1) \int_{R_2} p(x | C_1) dx + P(C_2) \int_{R_1} p(x | C_2) dx.$$

Teoria da decisão Bayesiana




$$p_e = P(C_1) \int_{R_2} p(x | C_1) dx + P(C_2) \int_{R_1} p(x | C_2) dx .$$

$$P(C_i | x) = \frac{p(x | C_i) P(C_i)}{p(x)} ,$$

$$p_e = \int_{R_2} P(C_1 | x) p(x) dx + \int_{R_1} P(C_2 | x) p(x) dx .$$

Teoria da decisão Bayesiana




$$p_e = P(C_1) \int_{R_2} p(x | C_1) dx + P(C_2) \int_{R_1} p(x | C_2) dx .$$

$$P(C_i | x) = \frac{p(x | C_i) P(C_i)}{p(x)} ,$$

$$p_e = \int_{R_2} P(C_1 | x) p(x) dx + \int_{R_1} P(C_2 | x) p(x) dx .$$

$$P(C_1) = \int_{R_1} P(C_1 | x) p(x) dx + \int_{R_2} P(C_1 | x) p(x) dx .$$


Teoria da decisão Bayesiana



$$p_e = \int_{R_2} P(C_1 | x)p(x)dx + \int_{R_1} P(C_2 | x)p(x)dx .$$

$$P(C_1) = \int_{R_1} P(C_1 | x)p(x)dx + \int_{R_2} P(C_1 | x)p(x)dx .$$

Teoria da decisão Bayesiana



$$p_e = \int_{R_2} P(C_1 | x) p(x) dx + \int_{R_1} P(C_2 | x) p(x) dx .$$


$$P(C_1) = \int_{R_1} P(C_1 | x) p(x) dx + \int_{R_2} P(C_1 | x) p(x) dx .$$

$$p_e = P(C_1) - \int_{R_1} (P(C_1 | x) - P(C_2 | x)) p(x) dx .$$

- A probabilidade de erro é minimizada quando $P(C_1 | x) > P(C_2 | x)$ em R_1 .



Teoria da decisão Bayesiana

- Classificação ótima:
- Se $P(C_1 | x) > P(C_2 | x)$
então classifique $x \in C_1$
- Se $P(C_2 | x) > P(C_1 | x)$
então classifique $x \in C_2$




Classificadores probabilísticos

- Erro associado à classificação:
- Se movermos x_0 para a esquerda, há um aumento do erro, indicado pela área em cinza




Teoria da decisão Bayesiana

- A classificação pode ser feita de duas maneiras:
- Estimação paramétrica
- Estimação não-paramétrica



$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$



Classificação Bayesiana: estimação paramétrica

- A estimação dos parâmetros da distribuição $p(\mathbf{x} | C_i), i = 1, 2, \dots, k$, pode ser feita utilizando-se o método da maximização da verossimilhança.
- O objetivo é estimar os parâmetros da função densidade de probabilidade usando um conjunto de vetores de características de cada classe.
- Notem que utilizamos sempre o conjunto de treinamento para efetuarmos a estimação.

Classificação Bayesiana: estimação paramétrica

- Sejam $X_1, X_2, \dots, X_n$ uma amostra aleatória da população.
- Assumindo independência dos elementos da amostra, temos:

$$p(X; \theta) = p(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n) = \prod_{i=1}^n p(\mathbf{x}_i; \theta),$$

- O estimador de máxima verossimilhança é dado por:

$$\hat{\theta} = \operatorname{argmax}_{\theta} \prod_{i=1}^n p(\mathbf{x}_i; \theta).$$

Classificação Bayesiana: estimação paramétrica

- O estimador de máxima verossimilhança é dado por:

$$\hat{\theta} = \operatorname{argmax}_{\theta} \prod_{i=1}^n p(\mathbf{x}_i; \theta).$$

- Ou ainda: $L(\theta) = \log p(X; \theta) = \sum_{i=1}^n \log p(X; \theta).$

- Para encontrarmos os estimadores de máxima verossimilhança, calculamos a derivada:

$$\frac{\partial L(\theta)}{\partial \theta} = 0.$$

Classificação Bayesiana: estimação paramétrica

- Os estimadores de máxima verossimilhança são assintoticamente não-viesados, isto é, na média, converge para o valor real quando o número de amostras é grande:


$$\lim_{n \rightarrow \infty} E[\hat{\theta}] = \theta_0,$$

- São assintoticamente consistentes, isto é, a variância do estimador tende a zero quando o tamanho da amostra é grande, $\lim_{n \rightarrow \infty} E[||\hat{\theta} - \theta_0||^2] = 0$.
- Também são assintoticamente eficientes, isto é, ele obedece à desigualdade de Cramer-Rao, e são os estimadores com menor variância dentre todos os estimadores possíveis.

Classificação Bayesiana: estimação paramétrica

- Exemplo: Assuma que os vetores $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ foram amostrados a partir de uma distribuição normal com vetor de médias μ e matriz de covariância Σ . Vamos determinar o estimador de máxima verossimilhança para a média.

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp \left(-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right)$$



Classificação Bayesiana: estimação paramétrica

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp \left(-\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right)$$

- A função de máxima verossimilhança:

$$L(\mu) = \log \prod_{i=1}^n p(\mathbf{x}_i; \mu) = \log \prod_{i=1}^n \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right)$$

$$L(\mu) = -\frac{n}{2} \log[(2\pi)^d |\Sigma|] - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu)$$

Classificação Bayesiana: estimação paramétrica

$$L(\mu) = -\frac{n}{2} \log[(2\pi)^d |\Sigma|] - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu)$$


- Tomando o gradiente com relação ao vetor média μ e igualando a zero, obtemos:

$$\frac{\partial L(\mu)}{\partial \mu} = \left[\frac{\partial L}{\partial \mu_1}, \dots, \frac{\partial L}{\partial \mu_d} \right]^T = \mathbf{0},$$

$$\sum_{i=1}^n (\mathbf{x}_i - \mu) = \mathbf{0}$$


$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

Classificação Bayesiana: distribuições normais



$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^{d/2} |\Sigma|^{1/2}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right)$$




Classificadores probabilísticos


- Caso bidimensional:

$$\sigma = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$


$$\sigma_1^2 = \sigma_2^2$$



$$\sigma_1^2 > \sigma_2^2$$




$$\sigma_1^2 < \sigma_2^2$$



Classificação Bayesiana: distribuições normais

- Caso bidimensional:

$$\sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$



$$\sigma_1^2 = 15, \sigma_2^2 = 3, \sigma_{12} = 6$$

Classificação Bayesiana: distribuições normais

- Python

Classificação Bayesiana: estimação não-paramétrica


- Seja $(X_1, X_2, \dots, X_n)$ uma amostra aleatória unidimensional identicamente distribuída de acordo com alguma função de distribuição f não conhecida.
- Para estimarmos o formato de f , usamos um estimador (*kernel density estimator*):

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

- onde K é a função kernel.


Classificação Bayesiana: estimação não-paramétrica

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$



Classificação Bayesiana: estimação não-paramétrica

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$




Classificação Bayesiana: estimação não-paramétrica

- Python

Naive Bayes

Teoria da decisão Bayesiana

- Se $P(C_1 | x) > P(C_2 | x)$ então classifique $x \in C_1$
- Se $P(C_2 | x) > P(C_1 | x)$ então classifique $x \in C_2$



Teoria da decisão Bayesiana

- Na decisão Bayesiana, a principal limitação é que na maioria das vezes, não conhecemos a distribuição de probabilidade conjunta

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i)P(C_i)}{p(\mathbf{x})},$$

- A sua estimação é bastante complicada, principalmente se a dimensão dos dados (número de atributos) é muito alta.

Teoria da decisão Bayesiana

- Na decisão Bayesiana, a principal limitação é que na maioria das vezes, não conhecemos a distribuição de probabilidade conjunta

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i)P(C_i)}{p(\mathbf{x})},$$

- A sua estimação é bastante complicada, principalmente se a dimensão dos dados (número de atributos) é muito alta.
- Solução simples: assumir que os atributos são independentes.

Naive Bayes

- Naive Bayes: assume independência entre os atributos:

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i)P(C_i)}{p(\mathbf{x})},$$

$$p(\mathbf{x} | C_i) = \prod_{j=1}^d p(x_j | C_i) \quad i = 1, 2, \dots, k.$$

- Classificação usa a regra de Bayes:

$$C_m = \operatorname{argmax}_{i \in \{1, \dots, M\}} p(C_i) \prod_{j=1}^d p(x_j | C_i),$$

Naive Bayes

- **Exemplo:** Como diagnosticar um paciente?

$X = (\text{Calafrios} = \text{Sim}, \text{Coriza} = \text{Não}, \text{Cefaleia} = \text{média}, \text{febre} = \text{Não})$

$X_1 = \text{Calafrios}$	$X_2 = \text{Coriza}$	$X_3 = \text{Cefaleia}$	$X_4 = \text{Febre}$	Gripe
Sim	Não	Média	Sim	Não
Sim	Sim	Não	Não	Sim
Sim	Não	Forte	Sim	Sim
Não	Sim	Média	Sim	Sim
Não	Não	Não	Não	Não
Não	Sim	Forte	Sim	Sim
Não	Sim	Forte	Não	Não
Sim	Sim	Média	Sim	Sim

Naive Bayes

- **Exemplo:** Como diagnosticar um paciente?

$X = (\text{Calafrios} = \text{Sim}, \text{Coriza} = \text{Não}, \text{Cefaleia} = \text{média}, \text{febre} = \text{Não})$

- Precisamos calcular:

$$P(\text{Gripe} = \text{Sim} \mid \mathbf{x}) \text{ e } P(\text{Gripe} = \text{Nao} \mid \mathbf{x})$$

$X_1 = \text{Calafrios}$	$X_2 = \text{Coriza}$	$X_3 = \text{Cefaleia}$	$X_4 = \text{Febre}$	Gripe
Sim	Não	Média	Sim	Não
Sim	Sim	Não	Não	Sim
Sim	Não	Forte	Sim	Sim
Não	Sim	Média	Sim	Sim
Não	Não	Não	Não	Não
Não	Sim	Forte	Sim	Sim
Não	Sim	Forte	Não	Não
Sim	Sim	Média	Sim	Sim

Naive Bayes

- **Exemplo:** Probabilidade do paciente estar gripado:

$X = (\text{Calafrios} = \text{Sim}, \text{Coriza} = \text{Não}, \text{Cefaleia} = \text{média}, \text{febre} = \text{Não})$

$$P(\text{Gripe} = \text{Sim} \mid \mathbf{x}) = P(\mathbf{x} \mid \text{Gripe} = \text{Sim})P(\text{Gripe} = \text{Sim}).$$

$$P(\mathbf{x} \mid \text{Gripe} = \text{Sim}) = P(\text{Calafrios} = \text{Sim} \mid \text{Gripe} = \text{Sim}) \times P(\text{Coriza} = \text{Não} \mid \text{Gripe} = \text{Sim}) \times \\ P(\text{Cefaleia} = \text{média} \mid \text{Gripe} = \text{Sim}) \times P(\text{Febre} = \text{Não} \mid \text{Gripe} = \text{Sim})$$

Naive Bayes

3/5

1/5

$$P(\mathbf{x} \mid \text{Gripe} = \text{Sim}) = P(\text{Calafrios} = \text{Sim} \mid \text{Gripe} = \text{Sim}) \times P(\text{Coriza} = \text{Não} \mid \text{Gripe} = \text{Sim}) \times$$
$$P(\text{Cefaleia} = \text{média} \mid \text{Gripe} = \text{Sim}) \times P(\text{Febre} = \text{Não} \mid \text{Gripe} = \text{Sim})$$

2/5 1/5

$X_1 = \text{Calafrios}$	$X_2 = \text{Coriza}$	$X_3 = \text{Cefaleia}$	$X_4 = \text{Febre}$	Gripe
Sim	Não	Média	Sim	Não
Sim	Sim	Não	Não	Sim
Sim	Não	Forte	Sim	Sim
Não	Sim	Média	Sim	Sim
Não	Não	Não	Não	Não
Não	Sim	Forte	Sim	Sim
Não	Sim	Forte	Não	Não
Sim	Sim	Média	Sim	Sim

$$P(X \mid \text{Gripe} = \text{sim}) = (3/5)(1/5)(2/5)(1/5) = 0,006$$

Naive Bayes

- **Exemplo:** Probabilidade do paciente não estar gripado:

$X = (\text{Calafrios} = \text{Sim}, \text{Coriza} = \text{Não}, \text{Cefaleia} = \text{média}, \text{febre} = \text{Não})$

$$P(\text{Gripe} = \text{Nao} \mid \mathbf{x}) = P(\mathbf{x} \mid \text{Gripe} = \text{Nao})P(\text{Gripe} = \text{Nao}).$$

$$P(\mathbf{x} \mid \text{Gripe} = \text{Nao}) = P(\text{Calafrios} = \text{Sim} \mid \text{Gripe} = \text{Nao}) \times P(\text{Coriza} = \text{Não} \mid \text{Gripe} = \text{Nao}) \times \\ P(\text{Cefaleia} = \text{média} \mid \text{Gripe} = \text{Nao}) \times P(\text{Febre} = \text{Não} \mid \text{Gripe} = \text{Nao})$$

Naive Bayes

1/3

2/3

$$P(\mathbf{x} \mid \text{Gripe} = \text{Nao}) = P(\text{Calafrios} = \text{Sim} \mid \text{Gripe} = \text{Nao}) \times P(\text{Coriza} = \text{N\~ao} \mid \text{Gripe} = \text{Nao}) \times \\ P(\text{Cefaleia} = \text{m\~edia} \mid \text{Gripe} = \text{Nao}) \times P(\text{Febre} = \text{N\~ao} \mid \text{Gripe} = \text{Nao})$$

1/3

2/3

$X_1 = \text{Calafrios}$	$X_2 = \text{Coriza}$	$X_3 = \text{Cefaleia}$	$X_4 = \text{Febre}$	Gripe
Sim	N\~ao	M\~edia	Sim	N\~ao
Sim	Sim	N\~ao	N\~ao	Sim
Sim	N\~ao	Forte	Sim	Sim
N\~ao	Sim	M\~edia	Sim	Sim
N\~ao	N\~ao	N\~ao	N\~ao	N\~ao
N\~ao	Sim	Forte	Sim	Sim
N\~ao	Sim	Forte	N\~ao	N\~ao
Sim	Sim	M\~edia	Sim	Sim

$$P(X \mid \text{Gripe} = \text{sim}) = (1/3)(2/3)(1/3)(2/3) = 0,019$$

Naive Bayes

Observação: Notem que essa não é a probabilidade do paciente não estar gripado, pois não dividimos pela evidência $P(\mathbf{x})$.

$$P(C_i | \mathbf{x}) = \frac{p(\mathbf{x} | C_i)P(C_i)}{p(\mathbf{x})},$$

$$P(x) = P(x | \text{Gripe} = \text{sim})P(\text{Gripe} = \text{sim}) + P(x | \text{Gripe} = \text{nao})P(\text{Gripe} = \text{nao}) = 0,006 \times (5/8) + 0,019 \times (3/8) = 0,011$$

Naive Bayes

$$P(\text{Gripe}=\text{Sim} \mid \mathbf{x}) = \frac{\overset{0,006}{p(\mathbf{x} \mid \text{Gripe}=\text{Sim})} \overset{5/8}{P(\text{Gripe}=\text{Sim})}}{\underset{0,011}{p(\mathbf{x})}} = 0,24$$

$$P(\text{Gripe}=\text{Nao} \mid \mathbf{x}) = \frac{\overset{0,019}{p(\mathbf{x} \mid \text{Gripe}=\text{Nao})} \overset{3/8}{P(\text{Gripe}=\text{Nao})}}{\underset{0,011}{p(\mathbf{x})}} = 0,76$$

Portanto, o paciente não está gripado!

Naive Bayes

- Caso os atributos sejam contínuos, podemos assumir uma distribuição de probabilidade (geralmente Normal) e assim obter a função de verossimilhança.

Naive Bayes: atributos contínuos

- Para cada atributo x_j , a sua distribuição de probabilidades é assumida como normal:

$$p(x_j | C_i) = \frac{1}{\sqrt{2\pi\sigma_{C_i}}} \exp \left[-\frac{1}{2} \left(\frac{x_j - \mu_{C_i}}{\sigma_{C_i}} \right)^2 \right].$$

- Assuma independência e calcule a distribuição conjunta para cada nova observação q :

$$p(\mathbf{x}_q | C_i) = \prod_{j=1}^d p(x_{q,j} | C_i) \quad i = 1, 2, \dots, k.$$

- Classifique de acordo com a classe mais provável.

$$\hat{y} = \arg \max_{i=1, \dots, k} P(C_i) \prod_{j=1}^d p(x_{qj} | C_i)$$

Naive Bayes


- **Propriedades**
- Apesar da limitação em assumir independência dos atributos, o classificador Naive Bayes é robusto e apresenta boa performance para muitos dados reais.
- Todas as probabilidades exigidas podem ser calculadas a partir dos dados de treinamento em uma passagem, o que torna o processo de aprendizado bastante rápido.
- O classificador Naive Bayes é ainda robusto a ruídos e atributos irrelevantes, pois nesse caso, a probabilidade de pertencer a cada classe será parecida, tendo assim pouca influência na classificação --- essa probabilidade seria análoga à uma constante multiplicativa em todas as distribuições.

Naive Bayes

- Python

Leitura adicional

- **Pattern Recognition**, Sergios Theodoridis, Konstantinos Koutroumbas, Academic Press.



Classificadores probabilísticos

Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists
<http://smlbook.org/>
- Probabilistic Machine Learning: An Introduction, Kevin Patrick Murphy.
<https://probml.github.io/pml-book/book1.html>

