

Regressão Logística


Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação


Universidade de São Paulo

francisco@icmc.usp.br


Regressão Logística



Regressão Logística



Regressão Logística



Regressão Logística

- Modelo de regressão linear:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_d X_d = \beta^T \mathbf{x}$$


- onde $\mathbf{x}^T = [1, x_1, x_2, \dots, x_d]$
- Se considerarmos a saída Y como um valor inteiro, podemos usar o modelo de regressão para realizarmos a classificação de dados.
- Vamos definir as probabilidade para o caso de duas classes:

$$p(y = 0 | \mathbf{X}) \text{ e } p(y = 1 | \mathbf{X})$$

Regressão Logística

- Vamos considerar a função logística:

$$h(z) = \frac{e^z}{1 + e^z}$$




- Essa função retorna valores no intervalo $[0,1]$.

Regressão Logística

- Usando a função logística:

$$p(y = 1 | \mathbf{x}) = \frac{e^{\beta^T \mathbf{x}}}{1 + e^{\beta^T \mathbf{x}}}$$

$$p(y = 0 | \mathbf{x}) = 1 - p(y = 1 | \mathbf{x}) = \frac{1}{1 + e^{\beta^T \mathbf{x}}}$$



- O aprendizado se resume a estimar o vetor de parâmetros β .
- Esse método é chamado regressão logística.

Regressão Logística

- Para estimar os parâmetros do modelo, usamos o conjunto de treinamento

$$T = \{(x_i, y_i)\}_{i=1}^N.$$

- Usando estimação por máxima verossimilhança:

$$\hat{\beta} = \operatorname{argmax}_{\beta} p(\mathbf{y} \mid \mathbf{X}; \beta).$$

- Assim, a máxima verossimilhança:

$$\ell(\beta) = p(\mathbf{y} \mid \mathbf{X}; \beta) = \prod_{i=1}^N p(y_i \mid x_i; \beta) = \prod_{i:y_i=1} p(y = 1 \mid \mathbf{x}_i; \beta) \prod_{i:y_i=0} p(y = 0 \mid \mathbf{x}_i; \beta)$$

$$\ell(\beta) = \prod_{i:y_i=1} \frac{e^{\beta^T \mathbf{x}_i}}{1 + e^{\beta^T \mathbf{x}_i}} \prod_{i:y_i=0} \frac{1}{1 + e^{\beta^T \mathbf{x}_i}}$$

- Para estimar os parâmetros, precisamos otimizar essa função em relação à beta.

$$\ell(\beta) = \prod_{i:y_i=1} \frac{e^{\beta^T \mathbf{x}_i}}{1 + e^{\beta^T \mathbf{x}_i}} \prod_{i:y_i=0} \frac{1}{1 + e^{\beta^T \mathbf{x}_i}}$$

- Para facilitar os cálculos, podemos a função logaritmo, que é uma função monotônica e logo, o máximo é o mesmo que o da verossimilhança:

$$\log \ell(\beta) = \sum_{i:y_i=1} \left(\beta^T \mathbf{x}_i - \log(1 + e^{\beta^T \mathbf{x}_i}) \right) - \sum_{i:y_i=0} \log(1 + e^{\beta^T \mathbf{x}_i})$$

- Calculando a derivada e igualando a zero:

$$\nabla_{\beta} \log \ell(\beta) = \sum_{i=1}^n \mathbf{x}_i \left(y_i - \frac{e^{\beta^T \mathbf{x}_i}}{1 + e^{\beta^T \mathbf{x}_i}} \right) = 0$$

- Como essa equação é não-linear, devemos resolvê-la numericamente, por exemplo, usando o método de Newton–Raphson.
- Com isso, determinamos os parâmetros do modelo e realizamos a classificação em uma das duas classes.

Regressão Logística

- A regressão logística não tem uma solução analítica fechada (como a regressão linear, que pode ser resolvida com álgebra matricial).
- Por isso, para ajustar os coeficientes, usamos métodos numéricos de otimização.
- O mais clássico é a descida do gradiente (gradient descent).

- A superfície de decisão pode ser calculada usando:

$$p(y = 1 | \mathbf{x}) = p(y = 0 | \mathbf{x})$$



$$\frac{e^{\beta^T \mathbf{x}}}{1 + e^{\beta^T \mathbf{x}}} = \frac{1}{1 + e^{\beta^T \mathbf{x}}}$$

- Ou seja, basta resolvermos:

$$\beta^T \mathbf{x} = 0$$

- A solução são hiperplanos. Logo, a superfície de separação são hiperplanos (lineares).


Regressão Logística




Regressão Logística X Redes Neurais

$$Z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_d X_d = \beta^T \mathbf{x}$$

$$p(y = 0 | \mathbf{x}) = \frac{1}{1 + e^{\beta^T \mathbf{x}}} \quad p(y = 1 | \mathbf{x}) = \frac{e^{\beta^T \mathbf{x}}}{1 + e^{\beta^T \mathbf{x}}}$$





Regressão Logística X Redes Neurais




Regressão Logística X Redes Neurais


- A regressão logística é equivalente a um neurônio com ativação sigmoide
- Em redes neurais, a saída binária é modelada por uma sigmoide ou softmax (multiclasse)
- A descida do gradiente é a base do backpropagation
- A logística é o 'bloco de construção' de classificadores neurais




Regressão Logística X Redes Neurais



Regressão Linear




Regressão Logística



Rede Neural


Uma rede neural pode ser vista como uma série de classificadores de regressão logística empilhados uns sobre os outros.

Regressão Logística X Redes Neurais



- Vantagens:
 - Fácil de implementar.
 - Não faz qualquer suposição sobre a distribuição das classes no espaço de atributos.
 - Pode ser facilmente generalizado para múltiplas classes.
 - É bastante rápido na predição do conjunto de teste.
 - Coeficientes podem ser usados para determinar a importância dos atributos.
- Limitações:
 - Se há poucos dados e muitos atributos, pode levar a overfitting.
 - As superfícies de separação são lineares.

Regressão Logística



- Origens matemáticas (século XIX)
 - O ponto de partida está na função logística, introduzida pelo matemático belga Pierre Franois Verhulst em 1838.
 - Verhulst usou a função logística para modelar o crescimento populacional, como alternativa ao modelo exponencial de Malthus.
 - A curva logística tinha a vantagem de incorporar um limite máximo de crescimento (capacidade de suporte).
 - Essa função mais tarde se tornaria a base da regressão logística.

Regressão Logística

- Consolidação estatística (início do século XX)
 - No início dos anos 1900, estatísticos buscavam alternativas ao modelo de regressão linear para lidar com variáveis dependentes binárias (sim/não, sucesso/fracasso).
 - Em 1935, Joseph Berkson, médico e estatístico norte-americano, propôs formalmente a regressão logística como modelo estatístico para dados binários.
 - Ele apresentou a ideia em um artigo seminal ("***Application of the Logistic Function to Bio-Assay***"), no contexto da farmacologia e bioestatística.
 - Berkson cunhou o termo "logit", em analogia ao "probit" (já usado por Ronald A. Fisher e Chester Bliss no modelo probit, baseado na função normal).

Regressão Logística

- Difusão em biometria e ciências sociais (décadas de 1940–1960)
 - A regressão logística começou a ser usada em biometria, para analisar experimentos biológicos e médicos.
 - Paralelamente, foi aplicada em psicologia e ciências sociais, para modelar respostas dicotômicas (por exemplo, atitudes sim/não em pesquisas).
 - Nesse período, a logística competia com o modelo probit, mas ganhou destaque por ser matematicamente mais simples e computacionalmente eficiente.

Regressão Logística

- Expansão com métodos computacionais (décadas de 1970–1980)
 - Com a popularização dos computadores, a regressão logística se tornou uma das ferramentas padrão em estatística aplicada.
 - Foi usada em epidemiologia, ciências sociais e economia para modelar eventos binários (como adoecer/não adoecer, votar/não votar).
 - Nessa época, também foram desenvolvidas extensões:
 - Regressão logística multinomial (para variáveis dependentes com mais de duas categorias).
 - Regressão logística ordinal (para respostas em escala ordenada, como níveis de satisfação).

Regressão Logística

- Integração ao aprendizado de máquina (décadas de 1990–2000)
 - A regressão logística se consolidou como um classificador discriminativo fundamental, ao lado do Naive Bayes e do perceptron.
 - Tornou-se referência como método linear simples, mas com interpretação probabilística.
- Usada em:
 - NLP (processamento de linguagem natural).
 - Visão computacional (primeiros classificadores de imagens).
 - Modelagem de risco (em finanças e crédito).

Regressão Logística

- Papel atual (século XXI)
 - Embora métodos mais complexos (árvores, random forests, deep learning) tenham se popularizado, a regressão logística continua extremamente usada por ser:
 - Simples de interpretar (coeficientes como log-odds).
 - Eficiente computacionalmente.
 - Base para modelos mais avançados (softmax em redes neurais é uma generalização da logística).
 - Hoje aparece em:
 - Medicina (predição de risco).
 - Ciência política (análise de comportamento eleitoral).
 - Aprendizado de máquina como baseline de classificação.

Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists
<http://smlbook.org/>
- "Probabilistic Machine Learning: An Introduction" (2022)
Kevin Murphy.
- <https://probml.github.io/pml-book/>

