

Ensembles methods

Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

francisco@icmc.usp.br

Processo de tomada de decisão

- Em muitos problemas, procuramos uma **segunda, terceira ou quarta opinião**.
 - Tratando de assuntos financeiros, médicos, sociais entre outros.
- Atribuímos **pesos/valores a cada opinião**;
- Com a combinação das opiniões se espera obter **uma opinião que seja a mais bem informada de todas**;
- O processo de consultar “alguns especialistas” antes de tomar uma decisão é um processo da natureza humana.
- Apenas recentemente o mesmo foi descoberto pela comunidade de inteligência computacional.

Ensemble methods

- Um **classificador ensemble** (comitê de *learners*, mistura de especialistas ou sistema de classificadores múltiplo) é um sistema que combina classificadores treinados individualmente para se chegar a uma solução melhor do que aquela obtida usando classificadores individuais.



Histórico

- Primeiro trabalho datado de 1979 por Dasarathy e Sheela com discussão sobre o particionamento do espaço de características usando dois ou mais classificadores;
- Em 1990, Hansen e Salamon mostraram que a generalização de uma rede neural pode melhorar usando ensembles;
- Surgimento dos algoritmos de **Bagging**, **Boosting**, **AdaBoost**, novas abordagens, etc.
- Livro sobre Combining Pattern Classifiers: Methods and Algorithms por Ludmila I. Kuncheva em 2004.

Ensemble methods

- Também conhecido sobe vários outros nomes:
 - ***Multiple classifier systems, committee of classifiers, ou mixture of experts.***
- Tem mostrado produzir resultados favoráveis comparados a sistemas com um único especialista;
- Bons resultados são encontrados em várias aplicações em uma larga variedade de cenários.

Ensemble methods


- **Razões Estatísticas**
 - Quando se trabalha classificadores:
 - Um bom desempenho no conjunto de treinamento não prediz um bom desempenho de generalização;
 - Um conjunto de classificadores com desempenhos similares no conjunto de classificação podem ter diferentes desempenhos de generalização;
 - Mesmo classificadores com desempenhos de generalização similares podem trabalhar diferentemente;
 - A combinação das saídas produzidas pelos classificadores reduz o risco de uma infeliz escolha por um classificador com um pobre desempenho
 - Não seguir apenas a “recomendação” de um único especialista.

Ensemble methods

- **Dividir e Conquistar**
 - **Dividir:** em vez de depender de um único modelo complexo, treinamos vários modelos mais simples (classificadores fracos).
 - **Conquistar:** combinamos as previsões desses modelos simples (via votação, média ponderada ou meta-modelo) para obter um classificador mais forte e robusto.


Ensemble methods

- **Dividir e Conquistar**
- Independente da quantidade de dados alguns problemas são muito difíceis de serem resolvidos por um dado classificador:



Ensemble methods


- Dividir e Conquistar
- A fronteira de decisão que separa os dados de diferentes classes pode ser muito complexa ou estar fora do escopo do classificador.




Ensemble methods

- **Dividir e Conquistar**
- A idéia é que o sistema de classificação siga a abordagem dividir-para-conquistar;
- O espaço de dados é dividido em porções menores e mais “fáceis” de aprender por diferentes classificadores;
- Assim a linha base da fronteira de decisão pode ser aproximada por meio de uma combinação apropriada dos diferentes classificadores.

Ensemble methods





Ensemble methods


- **Métodos:**
 - **Bagging (Bootstrap Aggregating)**
 - Divide os dados em diferentes subconjuntos (via amostragem bootstrap).
 - Cada modelo resolve uma parte do problema.
 - Conquista ao combinar resultados (ex.: Random Forest).
 - **Boosting**
 - Divide o problema em etapas sequenciais: cada classificador corrige os erros do anterior.
 - Conquista ao somar as previsões ponderadas.
 - **Stacking**
 - Divide entre diferentes algoritmos (SVM, árvores, regressão, etc.).
 - Conquista ao usar um meta-classificador que integra os resultados.

Ensemble methods

- **Bagging:**

- **Pergunta:** Dado um modelo com baixo viés e alta variância, é possível reduzir a variância e preservar o viés?
- Seja $z_1, z_2, \dots, z_B$ uma coleção de variáveis aleatórias identicamente distribuídas, mas possivelmente dependentes, com esperança $E[z_i] = \mu$ e $\text{Var}[z_i] = \sigma^2$
- Para essa coleção, pode-se mostrar:

$$\mathbb{E} \left[\frac{1}{B} \sum_{b=1}^B z_b \right] = \mu,$$
$$\text{Var} \left[\frac{1}{B} \sum_{b=1}^B z_b \right] = \frac{1 - \rho}{B} \sigma^2 + \rho \sigma^2.$$




Ensemble methods

- Bagging:

- Ou seja, quando temos uma amostra de uma distribuição, a média se mantém, mas a variância diminui se a correlação for menor do que um.

$$\mathbb{E} \left[\frac{1}{B} \sum_{b=1}^B z_b \right] = \mu,$$
$$\text{Var} \left[\frac{1}{B} \sum_{b=1}^B z_b \right] = \frac{1-\rho}{B} \sigma^2 + \rho \sigma^2.$$



Ensemble methods

- **Bagging:**

- A variância de predições obtidas de modelos identicamente distribuídos, cada um com baixo viés, pode ser reduzida se calcularmos a média dessas previsões.

- **Problema:** como gerar mais dados?

- **Bagging: Bootstrap Aggregating**

- **Ideia:** Selecionar B amostras **com reposição** a partir do conjunto de treinamento.

Cada amostra tem o mesmo tamanho que o conjunto de treinamento.

- Usar cada amostra para treinar um classificador.

- Predição:

$$\hat{y}_{\star}^{\text{avg}} = \frac{1}{B} \sum_{b=1}^B \hat{y}_{\star}^b.$$

Ensemble methods

- **Bagging:**

- Considere um objeto específico x_i . Em um único sorteio, a probabilidade de que esse objeto não seja escolhido é: $1 - \frac{1}{N}$.
- Como são realizados N sorteios independentes, a probabilidade de que x_i nunca seja escolhido é $\left(1 - \frac{1}{N}\right)^N$.
- Quando N é grande, temos o limite: $\left(1 - \frac{1}{N}\right)^N \rightarrow e^{-1}$.
- Portanto, a probabilidade de que o objeto x_i apareça pelo menos uma vez na amostra bootstrap é $1 - \left(1 - \frac{1}{N}\right)^N = 1 - e^{-1} = 1 - \frac{1}{e} \approx 0,632$.
- Assim, cada amostra bootstrap contém, em média, cerca de **63,2%** dos objetos distintos da base original.

Ensemble methods

- **Bagging:**


- Depois de treinar k classificadores, um objeto do conjunto de teste é associado à classe que receber o maior número de votos.

Algorithm 5.6 Bagging algorithm.

- 1: Let k be the number of bootstrap samples.
 - 2: **for** $i = 1$ to k **do**
 - 3: Create a bootstrap sample of size N , D_i .
 - 4: Train a base classifier C_i on the bootstrap sample D_i .
 - 5: **end for**
 - 6: $C^*(x) = \operatorname{argmax}_y \sum_i \delta(C_i(x) = y)$.
 $\{\delta(\cdot) = 1 \text{ if its argument is true and } 0 \text{ otherwise}\}.$
-

Ensemble methods

- Bagging:
 - O método de classificação pode ser qualquer modelo preditivo.
 - Exemplo: para uma árvore de decisão:



Ensemble methods

- **Boosting:**

- É um método iterativo usado para mudar a distribuição dos dados de forma adaptativa.
- Isto é feito modificando-se o conjunto de treinamento de modo a colocar maior ênfase nas observações que o modelo não conseguiu acertar.
- A ideia é transformar um conjunto de modelos pouco precisos em um método preciso.

Ensemble methods

- **Boosting:**
 - Algoritmo:
 - Inicialmente, cada observação possui o mesmo peso.
 - A seguir, o algoritmo ajusta os pesos de forma iterativa.
 - Observações classificadas erroneamente recebem maior peso.
 - Quanto maior o peso, maior é a probabilidade de ser escolhido nos passos posteriores.

Original Data	1	2	3	4	5	6	7	8	9	10
Boosting (Round 1)	7	3	2	8	7	9	4	10	6	3
Boosting (Round 2)	5	4	9	4	2	5	1	7	4	2
Boosting (Round 3)	4	4	8	10	4	5	4	6	3	4

- Exemplo 4 é difícil de acertar.

Ensemble methods

- **AdaBoost:**

- Uma das implementações mais populares é o AdaBoost.
- O método associa um peso inicial $w_i = 1/N$ a cada observação (x_i, y_i) . A seguir, o peso é atualizado por:

$$w_i^{(j+1)} = \frac{w_i^{(j)}}{Z_j} \times \begin{cases} \exp^{-\alpha_j} & \text{if } C_j(\mathbf{x}_i) = y_i \\ \exp^{\alpha_j} & \text{if } C_j(\mathbf{x}_i) \neq y_i \end{cases},$$

- onde:

$$\alpha_i = \frac{1}{2} \ln \left(\frac{1 - \epsilon_i}{\epsilon_i} \right). \quad \epsilon_i = \frac{1}{N} \left[\sum_{j=1}^N w_j I \left(C_i(\mathbf{x}_j) \neq y_j \right) \right],$$


- Z_j é uma constante normalizadora.
- As amostras são sorteadas de acordo com o peso. Quanto maior o peso, maior a chance de ser selecionado.

Ensemble methods

- **Boosting:**
 - Propriedades:
 - Se os dados apresentarem ruídos, pode ocorrer overfitting.
 - O algoritmo precisa lidar com duas escolhas importantes:
 - Qual classificador de base será usado (geralmente usa-se árvores de decisão).
 - Quantas interações (B) serão usadas?
 - Boosting ajusta o viés e variância.
 - Enquanto que o método bagging necessita de um classificador com baixo viés, mas pode apresentar alta variância, boosting não requer que o classificador tenham baixo viés.
 - No entanto, bagging não produz overfitting.

Ensemble methods


- Florestas aleatórias (random forests)
 - É parecido com os métodos bagging e boosting, mas também amostra os atributos.



Ensemble methods

- Florestas aleatórias


- A amostragem dos atributos permite que as árvores geradas não sejam dominadas por um atributo com alto poder de discriminação.



Ensemble methods

- **Florestas aleatórias:**

- O Random Forest é um método de ensemble baseado em Bagging que usa várias árvores de decisão para construir um classificador mais robusto e preciso.
- Divide o problema em várias árvores de decisão (cada uma simples e instável sozinha).
- Conquista combinando suas previsões (votação ou média).



Ensemble methods

- **Florestas aleatórias:**
 - **Amostragem bootstrap dos dados**
 - Para cada árvore, cria-se uma amostra com reposição do conjunto de treinamento.
 - Isso gera diversidade entre as árvores.
 - **Seleção aleatória de atributos**
 - Em cada nó da árvore, em vez de considerar todas as variáveis, o algoritmo escolhe um subconjunto aleatório.
 - Isso reduz a correlação entre as árvores e aumenta a diversidade.
 - **Treinamento de várias árvores de decisão**
 - Cada árvore é treinada de forma independente, com seus dados e atributos aleatórios.
 - **Combinação das previsões**
 - Para classificação: votação majoritária.
 - Para regressão: média das previsões.

Florestas aleatórias

- **Vantagens:**

- Alta acurácia mesmo com parâmetros simples.
- Robustez contra overfitting (melhor do que uma única árvore).
- Permite medir a importância das variáveis.
- Funciona bem em problemas de alta dimensionalidade.


- **Desvantagens:**

- Menor interpretabilidade que uma única árvore.
- Pode ser computacionalmente custoso em conjuntos muito grandes.
- Previsão mais lenta quando há muitas árvores.

Florestas aleatórias

- **Rankeamento dos atributos:**

- Cada atributo (feature) recebe uma pontuação de importância.
- Essa importância mede o quanto o atributo contribui para reduzir a incerteza (ou o erro) nas árvores do Random Forest.
- Assim, conseguimos ordenar (rankeamento) as variáveis, da mais relevante para a menos relevante.




Florestas aleatórias

- Existem dois métodos principais:
 - **Gini Importance (ou Impureza Diminuída Média)**
 - Cada vez que uma variável é usada para dividir um nó, o algoritmo calcula o quanto a impureza (ex.: índice de Gini, entropia) foi reduzida.
 - A importância final da variável é a soma dessas reduções, normalizada.
 - **Permutation Importance (Importância por permutação)**
 - Depois do modelo treinado, embaralha-se os valores de uma variável.
 - Se o desempenho do modelo cai bastante, significa que a variável é importante.
 - Mais robusto, mas também mais custoso computacionalmente.

Florestas aleatórias

- Para que serve o rankeamento dos atributos?
- **Seleção de variáveis:** podemos reduzir o modelo para usar apenas as variáveis mais relevantes.
- **Interpretação:** entender melhor os fatores que influenciam a predição.
- **Ciência de dados aplicada:** ajuda a gerar hipóteses em biologia, medicina, economia etc.



Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists
<http://smlbook.org/>

