

Agrupamento de dados

Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

francisco@icmc.usp.br

Técnicas de agrupamento

- K-means,
- Agrupamento Hierárquico,
- Avaliando Agrupamentos

Agrupamento de dados

- **Definição:**
 - Dado um conjunto de objetos, agrupar os objetos em grupos (*clusters*) baseados na similaridade entre eles.
 - Exemplo: Como agrupar esses animais?



Com bico



Sem bico

Agrupamento de dados

- Definição:
 - Dado um conjunto de objetos, agrupar os objetos em grupos (*clusters*) baseados na similaridade entre eles.
 - Exemplo: Como agrupar esses animais?

Água




Terra



Agrupamento de dados

- Definição:
 - Dado um conjunto de objetos, agrupar os objetos em grupos (*clusters*) baseados na similaridade entre eles.
 - Exemplo: Como agrupar esses animais?



Ovíparo



Mamífero

Agrupamento de dados

- **Limitação:**
 - Não há uma definição clara sobre o significado de “cluster” e como encontrar os grupos.

Quantos clusters?



Dois clusters?



Quatro clusters?




Seis clusters?



Agrupamento de dados

- **Objetivo:**
 - Encontrar os grupos de objetos tal que objetos no mesmo grupo serão similares (ou relacionados) um ao outro e diferentes (ou não relacionados) a objetos nos outros grupos.



Agrupamento de dados

- **Classificação X Agrupamento:**
 - **Classificação:** Usar exemplos conhecidos para treinar um classificador, que será usado para prever novos padrões.
 - **Agrupamento (clustering):** A partir de um conjunto de dados sem classificação, agrupar os elementos de acordo com as suas características, maximizando a similaridade entre os elementos no mesmo grupo e minimizando a similaridade entre os grupos.

Agrupamento de dados

- **Agrupamento Particional:**

- Um algoritmo de agrupamento particional (exclusivo) gera uma K-partição de **X**, **C**={ $C_1, C_2, \dots, C_K$ } ($K \leq N$), tal que:

- $C_i \neq \emptyset \ (i=1, \dots, K)$
- $\cup_{i=1} C_i = \mathbf{X}$
- $C_i \cap C_j = \emptyset \ (i, j=1, \dots, K \text{ e } i \neq j)$

Agrupamento de dados

- Como definir a similaridade entre os objetos?
- Precisamos definir uma medida de proximidade.
- **Medida de similaridade:** $d(X_i, X_i)$ é máxima.
 - Exemplo: Número de amigos compartilhados em uma rede social.
- **Medida de dissimilaridade:** $d(X_i, X_i) = 0$.
 - Exemplo: distância entre cidades (distância Euclidiana).

Agrupamento de dados

- **Medida de dissimilaridade:**

- $d(p, q) \geq 0$ para todo p e q , e $d(p, q) = 0$ se, e somente se, $p = q$,
- $d(p, q) = d(q, p)$ para todo p e q ,
- $d(p, r) \leq d(p, q) + d(q, r)$ para todo p, q , e r , onde $d(p, q)$ é a distância de dissimilaridade entre os pontos (objetos) p e q .

- **Medida de similaridade:**

- $s(p, q) = 1$ (ou máximo de similaridade) se $p = q$,
- $s(p, q) = s(q, p)$ para todo p e q , onde $s(p, q)$ é a similaridade entre os objetos p e q .

Agrupamento de dados

- Métricas de distância:

- Euclidiana $D(X, Y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad [0, \infty)$





- Minkowski $D(X, Y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}} \quad [0, \infty)$

- Cosseno $D(X, Y) = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n (x_i)^2} \sqrt{\sum_{i=1}^n (y_i)^2}} \quad [0, 1]$

- Pearson $D(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad [-1, 1]$


Agrupamento de dados

- Métricas de distância X topologia do espaço




Agrupamento de dados


- Tipos:



Partitional Clustering





Traditional Hierarchical Clustering



Traditional Dendrogram

Agrupamento de dados


- Representação dos grupos:



(c)

	1	2	3
a	0.4	0.1	0.5
b	0.1	0.8	0.1
c	0.3	0.3	0.4
...			

Matriz de probabilidades



Dendograma

Agrupamento de dados

- **Estágios:**
 - **Seleção de atributos:** Os atributos devem ser selecionados de modo que ocorra o mínimo de redundância entre eles.
 - **Medida de proximidade:** Esta medida deve quantificar o quão similar o dissimilar são os objetos.
 - **Critério de agrupamento:** Consiste de uma função custo ou algum tipo de regra.
 - **Algoritmo de agrupamento:** Consiste de um conjunto de passos para revelar a estrutura dos dados, baseados na medida de similaridade e no critério adotado.
 - **Validação dos resultados.**
 - **Interpretação dos resultados.**

K-means


K-means

- **Algoritmo:**
 - Selecione k pontos como centróides iniciais.
 - Repita:
 - Forme k grupos associando todos os pontos aos centróides mais próximos,
 - Calcule o centróide de cada grupo obtido.
 - Repita até que os centróides não mudem.




K-means


- Exemplo:




(a)




(b)




(c)



(d)




(e)



(f)


K-means: questões importantes

- Inicialização:
- O algoritmo é sensível à posição inicial das sementes.
- Importante rodar o algoritmo diversas vezes para obter resultados significativos.



K-means: questões importantes



- Qual o número de clusters?



K-means


- Limitações:

- É bastante susceptível a problemas quando clusters são de diferentes tamanhos.





K-means

- **Limitações:**
 - É bastante susceptível a problemas quando clusters são de diferentes densidades.



K-means

- Limitações:
 - É bastante susceptível a problemas quando clusters são de diferentes formatos (em geral não globulares).



K-means

- Métricas de distância:

- Euclidiana $D(X, Y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad [0, \infty)$





- Minkowski $D(X, Y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}} \quad [0, \infty)$

- Cosseno $D(X, Y) = \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n (x_i)^2} \sqrt{\sum_{i=1}^n (y_i)^2}} \quad [0, 1]$

- Pearson $D(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad [-1, 1]$


K-means

- Métricas de distância X topologia do espaço



K-means

- Limitações:
- Identifica clusters em dados aleatório.



K-means

- **Vantagens**

- Relativamente fácil de implementar.
- Interpretabilidade.
- Pode ser usado em grandes bancos de dados.
- Fácil de ser adaptado a novos exemplos.
- Há versões aprimoradas que tentam resolver a maior parte de suas limitações (métrica usada, número de clusters, inicialização).




Agrupamento Hierárquico

Agrupamento Hierárquico

- Como agrupá-los?





Agrupamento Hierárquico




Agrupamento Hierárquico

- Um algoritmo de agrupamento hierárquico gera uma estrutura aninhada (árvore) de $\mathbf{X}$, $\mathbf{H}=\{H_1, H_2, \dots, H_Q\}$ ($K \leq N$), tal que:
- $C_i \in H_m$ e $C_j \in H_l$ ($m > l$), implica que
 - $C_i \subseteq C_j$ ou
 - $C_i \cap C_j = \emptyset$ ($i, j, m, l = 1, \dots, Q$ e $i \neq j$)



Agrupamento Hierárquico




0 - [1. , 1.]
1 - [1.5, 1.]
2 - [3. , 3.]
3 - [3.5, 3.3]
4 - [2.5, 3.4]
5 - [2.5, 2.5]

D =

	0	1	2	3	4	5
0	[0. , 0.5 , 2.82 , 3.39 , 2.83 , 2.12]					
1	[0.5 , 0. , 2.5 , 3.04 , 2.6 , 1.8]					
2	[2.82 , 2.5 , 0. , 0.58 , 0.64 , 0.7]					
3	[3.39 , 3.04 , 0.58 , 0. , 1. , 1.28]					
4	[2.83 , 2.6 , 0.64 , 1. , 0. , 0.89]					
5	[2.12 , 1.8 , 0.7 , 1.28 , 0.89 , 0.]					


Agrupamento Hierárquico




0 - [1. , 1.]
1 - [1.5, 1.]
2 - [3. , 3.]
3 - [3.5, 3.3]
4 - [2.5, 3.4]
5 - [2.5, 2.5]

D =


	0	1	2	3	4	5
0	[0. , 0.5 , 2.82, 3.39, 2.83, 2.12]					
1	[0.5 , 0. , 2.5 , 3.04, 2.6 , 1.8]					
2	[2.82, 2.5 , 0. , 0.58, 0.64, 0.7]					
3	[3.39, 3.04, 0.58, 0. , 1. , 1.28]					
4	[2.83, 2.6 , 0.64, 1. , 0. , 0.89]					
5	[2.12, 1.8 , 0.7 , 1.28, 0.89, 0.]					



Agrupamento Hierárquico




Agrupamento Hierárquico



Critério de clusterização

- Iniciando com clusters individuais, definimos a matriz de proximidades.




	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						

Matriz de Proximidade

p1 p2 p3 p4 ... p9 p10 p11 p12


Critério de clusterização

- Depois de alguns passos, temos alguns clusters.




	C1	C2	C3	C4	C5
C1					
C2					
C3					
C4					
C5					

Matriz de proximidade




Critério de clusterização

- Nós queremos agrupar os clusters mais próximos (C2 e C5) e atualizar a matriz de proximidades.




	C1	C2	C3	C4	C5
C1					
C2					
C3					
C4					
C5					

Matriz de proximidades




Critério de clusterização

- Uma questão fundamental é:
Como realizar a atualização da matriz?




	C1	C2 U C5	C3	C4
C1		?		
C2 U C5	?	?	?	?
C3		?		
C4		?		

Matriz de proximidades



Critério de clusterização




- MIN (single linkage).
- MAX (complete linkage).
- Média dos grupos.
- Distância entre centróides.
- Outros métodos que usam uma função objetivo.
 - Método de Ward usa erro quadrático médio.

	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						

Matriz de proximidade

Critério de clusterização




- MIN (single linkage).
- MAX (complete linkage).
- Média dos grupos.
- Distância entre centróides.
- Outros métodos que usam uma função objetivo.
 - Método de Ward usa erro quadrático médio.

	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						

Matriz de proximidade

Critério de clusterização




- MIN (single linkage).
- **MAX (complete linkage).**
- Média dos grupos.
- Distância entre centróides.
- Outros métodos que usam uma função objetivo.
 - Método de Ward usa erro quadrático médio.

	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						

Matriz de proximidade

Critério de clusterização




- MIN (single linkage).
- MAX (complete linkage).
- Média dos grupos.
- Distância entre centróides.
- Outros métodos que usam uma função objetivo.
 - Método de Ward usa erro quadrático médio.

	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						

Matriz de proximidade

Critério de clusterização




- MIN (single linkage).
- MAX (complete linkage).
- Média dos grupos.
- **Distância entre centróides.**
- Outros métodos que usam uma função objetivo.
 - Método de Ward usa erro quadrático médio.

	p1	p2	p3	p4	p5	...
p1						
p2						
p3						
p4						
p5						
.						
.						
.						




Matriz de proximidade

Critério de clusterização


- **Método de Ward:** Em cada estágio, combinam-se os dois agrupamentos que apresentarem menor aumento na soma global de quadrados dentro dos agrupamentos.







Agrupamento Hierárquico







Método de Ward




Agrupamento Hierárquico



Agrupamento Hierárquico





Agrupamento Hierárquico

- **Vantagens**

- Fácil de ser implementado.
- Resultados são facilmente interpretados.

- **Desvantagens**


- Nem sempre fornece a melhor solução.
- Os resultados dependem do critério de agrupamento.
- É mais adequado para dados numéricos (usa distância).
- Sensível a outliers.

Avaliando Agrupamentos



Avaliando Agrupamentos

- Quando encontramos os clusters, uma questão básica é:
- Quão significativo é o agrupamento?
- A avaliação de agrupamentos pode ser usada:
 - Para evitar encontrar padrões em ruídos.
 - Para comparar diferentes métodos de agrupamento.
 - Para comparar clusters.

Avaliando Agrupamentos



- Podemos encontrar partições em dados aleatórios.





Avaliando Agrupamentos


- Medidas para avaliar agrupamentos:
 - **Índice externo:** Usado quando os rótulos dos objetos são conhecidos e queremos avaliar se os clusters correspondem aos grupos originais.
 - Exemplo: Medidas de entropia.
 - **Índice interno:** Usado para avaliar um agrupamento sem usar informações externas.
 - Exemplo: Some do erro quadrático.

Avaliando Agrupamentos


- **Matriz de similaridade:** ordena-se os objetos de acordo com os grupos e inspeciona-se visualmente. Cada elemento da matriz define a similaridade entre dois objetos (por exemplo, distância euclidiana entre dois vetores de atributos):



- Limitação: nem sempre essa estrutura é clara.




K-means



Avaliando Agrupamentos

- Elbow method:
- **Inertia coefficient:** distância quadrática média de cada observação ao centróide mais próximo.



Elbow Method

- **Elbow method (método do cotovelo):**
 - Usado para encontrar o melhor valor de k , podemos usar a distância média dos pontos dentro de um cluster até o seu centróide (*within-cluster sum of squares*) para diferentes valores de k .



$$WSS = \sum_{i=1}^{N_c} \sum_{\mathbf{x} \in C_i} d(\mathbf{x}, \bar{x}_{C_i})$$

onde C_i é um grupo e N_c é o número de grupos.

- WSS pode ser entendida como uma medida de compactação.

Elbow Method

- Elbow method (método do cotovelo):



Avaliando Agrupamentos

- **Silhouette**

- Para um dado i no cluster C_I :

$$a(i) = \frac{1}{|C_I| - 1} \sum_{j \in C_I, i \neq j} d(i, j)$$

$$b(i) = \min_{J \neq I} \frac{1}{|C_J|} \sum_{j \in C_J} d(i, j)$$

- **Silhouette:**



$$s(i) = \begin{cases} 1 - a(i)/b(i), & \text{if } a(i) < b(i) \\ 0, & \text{if } a(i) = b(i) \\ b(i)/a(i) - 1, & \text{if } a(i) > b(i) \end{cases}$$

$$-1 \leq s(i) \leq 1$$

- Valores próximos de 1 ($a(i) \ll b(i)$) indicam que o cluster C_I é adequado à observação i . Valores próximos de -1, indicam o contrário. $s(i) = 0$ indica que a observação está na borda de dois clusters.
- Silhouette score: $SC = \frac{1}{n} \sum_{i=1}^n s(i)$



Avaliando Agrupamentos

- Silhouette



Avaliando Agrupamentos


- Silhouette



Avaliando Agrupamentos

- **Índice externo:** Usado para avaliar um agrupamento quando se tem um ground truth (conhecemos as classes).

Dados da flor Iris projetados usando PCA



Avaliando Agrupamentos

- **Purity (Pureza):** mede o quão "puro" é cada cluster:

$$Purity(i) = \frac{1}{n_i} \max_{j=1}^k (|C_i \cap T_j|)$$

onde C_i representa a classe obtida e T_j é a partição esperada.

	iris-setosa	iris-versicolor	iris-virginica	
	T_1	T_2	T_3	n_i
C_1 (squares)	0	47	14	61
C_2 (circles)	50	0	0	50
C_3 (triangles)	0	3	36	39
m_j	50	50	50	$n = 100$

$$Purity(i) = \frac{1}{150}(47 + 50 + 36) = 0,887$$

Avaliando Agrupamentos

- Medidas baseadas em entropia

A entropia de um dado cluster é definida por:

$$H(C) = - \sum_{i=1}^r P(C_i) \log P(C_i)$$

$$P(C_i) = \frac{n_i}{n}$$

A entropia de uma dada partição:

$$H(T) = - \sum_{j=1}^k P(T_j) \log P(T_j)$$

$$P(T_j) = \frac{m_j}{n}$$

	iris-setosa	iris-versicolor	iris-virginica	
	T_1	T_2	T_3	n_i
C_1 (squares)	0	47	14	61
C_2 (circles)	50	0	0	50
C_3 (triangles)	0	3	36	39
m_j	50	50	50	$n = 100$

Avaliando Agrupamentos

- Medidas baseadas em entropia

A entropia condicional da partição dado o agrupamento C:

$$H(T|C) = - \sum_{i=1}^r \sum_{j=1}^k \frac{n_{ij}}{n} \log \frac{n_{ij}}{n_i}$$

$$H(T|C) = - \sum_{i=1}^r \sum_{j=1}^k p_{ij} \log \frac{p_{ij}}{p_{Ci}}$$

$$H(T|C) = - \sum_{i=1}^r \sum_{j=1}^k p_{ij} (\log p_{ij} - \log p_{Ci}) = - \sum_{i=1}^r \sum_{j=1}^k p_{ij} \log p_{ij} + \sum_{i=1}^r p_{Ci} \log p_{Ci}$$

$$H(T|C) = H(C, T) - H(C)$$

Avaliando Agrupamentos

- Medidas baseadas em entropia

Mutual information:

$$I(C, T) = \sum_{i=1}^r \sum_{j=1}^k p_{ij} \log \frac{p_{ij}}{p_{Ci} p_{Tj}}$$

Expandindo:

$$I(C, T) = H(T) - H(T|C)$$

$$I(C, T) = H(C) - H(C|T)$$

Normalized mutual information:

$$NMI(C, T) = \frac{I(C, T)}{\sqrt{H(C)H(T)}}$$

$$H(T|C) = - \sum_{i=1}^r \sum_{j=1}^k \frac{n_{ij}}{n} \log \frac{n_{ij}}{n_i}$$

- Medidas baseadas em entropia

	iris-setosa T_1	iris-versicolor T_2	iris-virginica T_3	n_i
C_1	0	47	14	61
C_2	50	0	0	50
C_3	0	3	36	39
m_j	50	50	50	$n = 100$

$$\begin{aligned} H(\mathcal{T}|C_1) &= -\frac{0}{61} \log_2 \left(\frac{0}{61} \right) - \frac{47}{61} \log_2 \left(\frac{47}{61} \right) - \frac{14}{61} \log_2 \left(\frac{14}{61} \right) \\ &= -0 - 0.77 \log_2(0.77) - 0.23 \log_2(0.23) = 0.29 + 0.49 = 0.78 \end{aligned}$$

$$H(\mathcal{T}|C_2) = 0 \quad H(\mathcal{T}|C_3) = 0.39$$

$$H(\mathcal{T}|C) = \frac{61}{150} \cdot 0.78 + \frac{50}{150} \cdot 0 + \frac{39}{150} \cdot 0.39 = 0.32 + 0 + 0.10 = 0.42$$

Avaliando Agrupamentos

- Normalized mutual information

	iris-setosa	iris-versicolor	iris-virginica	
	T_1	T_2	T_3	n_i
C_1	0	47	14	61
C_2	50	0	0	50
C_3	0	3	36	39
m_j	50	50	50	$n = 100$

$$H(\mathcal{T}) = -3 \left(\frac{50}{150} \log_2 \left(\frac{50}{150} \right) \right) = 1.585$$

$$H(\mathcal{C}) = - \left(\frac{61}{150} \log_2 \left(\frac{61}{150} \right) + \frac{50}{150} \log_2 \left(\frac{50}{150} \right) + \frac{39}{150} \log_2 \left(\frac{39}{150} \right) \right) \\ = 0.528 + 0.528 + 0.505 = 1.561$$

$$I(\mathcal{C}, \mathcal{T}) = \frac{47}{150} \log_2 \left(\frac{47 \cdot 150}{61 \cdot 50} \right) + \frac{14}{150} \log_2 \left(\frac{14 \cdot 150}{61 \cdot 50} \right) + \frac{50}{150} \log_2 \left(\frac{50 \cdot 150}{50 \cdot 50} \right) \\ + \frac{3}{150} \left(\log_2 \frac{3 \cdot 150}{39 \cdot 50} \right) + \frac{36}{150} \log_2 \left(\frac{36 \cdot 150}{39 \cdot 50} \right) \\ = 0.379 - 0.05 + 0.528 - 0.042 + 0.353 = 1.167$$

$$H(\mathcal{T} | \mathcal{C}) = - \sum_{i=1}^r \sum_{j=1}^k \frac{n_{ij}}{n} \log \frac{n_{ij}}{n_i}$$

$$H(\mathcal{T}) = - \sum_{j=1}^k P(\mathcal{T}_j) \log P(\mathcal{T}_j)$$

$$H(\mathcal{C}) = - \sum_{i=1}^r P(\mathcal{C}_i) \log P(\mathcal{C}_i) \quad P(\mathcal{T}_j) = \frac{m_j}{n}$$

$$I(\mathcal{C}, \mathcal{T}) = H(\mathcal{T}) - H(\mathcal{T} | \mathcal{C}) \quad P(\mathcal{C}_i) = \frac{n_i}{n}$$

$$NMI(\mathcal{C}, \mathcal{T}) = \frac{I(\mathcal{C}, \mathcal{T})}{\sqrt{H(\mathcal{T}) \cdot H(\mathcal{C})}} = \frac{1.167}{\sqrt{1.585 \times 1.561}} = 0.742$$

Avaliando Agrupamentos


- **Índice externo:** Outras medidas:
 - Maximum matching,
 - f-Measure

Agrupamento de dados: desafio

“The validation of clustering structures is the most difficult and frustrating part of cluster analysis.

Without a strong effort in this direction, cluster analysis will remain a black art accessible only to those true believers who have experience and great courage.”

Algorithms for Clustering Data, Jain and Dubes



Leitura adicional

- Machine Learning - A First Course for Engineers and Scientists

<http://smlbook.org/>

